TRABALHO DE CONCLUSÃO DE CURSO · GUIA PARA APRESENTAÇÃO

Como o pipeline de descoberta de miRNAs funciona

Da sequência madura **`AUGC...`** ao ranking integrado e à validação externa em soro: k-mers, seed, aprendizado Positive-Unlabeled e expressão.

43
miRNAs positivos curados

2.613
candidatos no Modelo 1

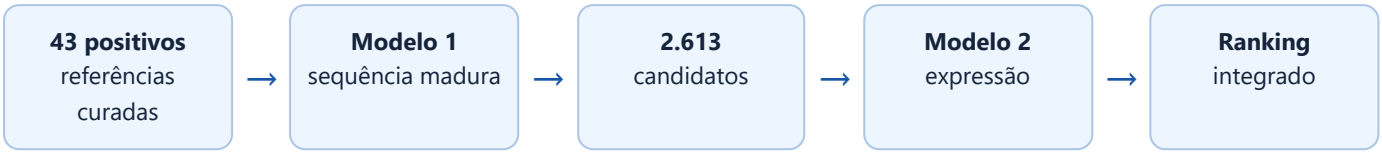
611
avaliados no Modelo 2

2.549
amostras na validação externa

Versão vigente em 10/10/2026 · Modelo centrado na sequência madura · TCC-miRNA-Model

1. Visão geral: duas perguntas, dois modelos

O projeto funciona como duas peneiras sucessivas. A primeira procura semelhança molecular com marcadores conhecidos; a segunda verifica associação de expressão nos pacientes.



> **Resposta curta para a banca:** o Modelo 1 prioriza candidatos por padrões da sequência madura; o Modelo 2 verifica se a expressão disponível separa doentes e saudáveis. Nenhum dos dois confirma sozinho um biomarcador.

Por que o hairpin não aparece mais?

O hairpin é biologicamente parte da formação do miRNA, mas foi retirado do pipeline para reduzir complexidade e manter a pergunta do TCC centrada no miRNA maduro. A primeira versão madura-only preservou o desempenho observado. Depois, novas representações exclusivamente maduras elevaram o percentil médio externo de 60,55% para 64,60%. Esse ganho é promissor, mas continua sendo uma comparação interna e não substitui uma coorte externa.

> **Escopo atual:** k-mers globais e posicionais, seed, comprimento, composição, entropia e motivos das extremidades 5p/3p da sequência madura. Hairpin, estrutura secundária e MFE não entram no modelo.

2. Os termos essenciais

Sequência madura
Pequeno RNA funcional após o processamento do precursor. É a sequência usada pelo Modelo 1.

Seed
Posições 2 a 8 da sequência madura. É importante para o reconhecimento de alvos e para agrupar miRNAs relacionados.

k-mer
Fragmento de comprimento k extraído da sequência. Ex.: para k=3, `AUG`, `UGC` e `GCU`.

Fração GC
Proporção de G e C na sequência madura. Resume sua composição.

Peso de evidência
Importância dada a cada positivo segundo a curadoria: alta=3, média=2, exploratória=1.

Família de seed
Grupo de marcadores com a mesma seed. É a unidade principal da validação.

Exemplo de quebra em k-mers

A U G C U A A C G U A

k	Fragmentos sucessivos	O que representa
2	`AU`, `UG`, `GC`, ...	Padrões muito locais e frequentes.
3	`AUG`, `UGC`, `GCU`, ...	Contexto local um pouco maior.
4	`AUGC`, `UGCU`, ...	Motivos mais específicos.

As contagens são normalizadas pelo total de fragmentos, evitando que uma sequência pareça mais importante apenas por ser um pouco maior. A configuração final usa k=2,3,4 e separa os motivos encontrados no começo, centro e fim da sequência. Essa posição importa porque o mesmo fragmento pode ter papéis diferentes dependendo de onde aparece.

Outras pistas extraídas do miRNA maduro

Composição
Frações de A, U, C e G e entropia, que resumem diversidade e equilíbrio da sequência.

Posição
K-mers separados nas regiões 5p, central e 3p, preservando onde cada padrão ocorreu.

Extremidades
Motivos exatos de 2, 3 e 4 bases no início e no fim do miRNA maduro.

3. Como o Modelo 1 aprende

1. Carrega os 43 miRNAs positivos e suas sequências maduras.
2. Converte cada sequência em um vetor com k-mers, seed, comprimento, composição, entropia, posição e motivos terminais.
3. Aplica o peso de evidência e divide o peso entre positivos da mesma família de seed.
4. Usa os demais miRNAs como conjunto *não rotulado*, e não como negativos biológicos.
5. Compara oito configurações dentro dos folds internos, sem consultar o teste externo.
6. Treina um ensemble final de 20 modelos, cada um com uma amostra diferente de 800 não rotulados.
7. Pontua cada candidato somente pelos modelos que não o usaram como contraste: pontuação out-of-bag.
8. Converte o logit em percentil dentro dos 2.613 candidatos e produz o ranking.

> **Por que Positive-Unlabeled?** Estar fora da lista dos 43 não significa ser biologicamente negativo. Alguns não rotulados podem ser candidatos verdadeiros ainda pouco estudados.

O que significa out-of-bag?

Se um candidato entrou como contraste temporário em determinado bag, aquele modelo não pode pontuá-lo. Ele recebe a média apenas dos bags em que ficou de fora. Isso reduz a penalização artificial causada pelo próprio processo PU.

Como medimos a estabilidade do ranking?

Além do percentil final, o pipeline registra, para cada candidato, a mediana, os quartis e a frequência com que ele aparece nos top 1%, 5%, 10% e 20% entre os modelos em que estava out-of-bag. Um candidato alto e consistente é mais confiável que outro que chega à mesma média por poucos resultados extremos.

O score é probabilidade de câncer?

Não. `score_modelo_sequencial` é uma posição relativa: 0,99 indica que o candidato ficou acima de aproximadamente 99% do universo avaliado. A probabilidade PU bruta também é apenas uma saída contrastiva interna.

4. Como testamos se o Modelo 1 generaliza

A avaliação esconde famílias inteiras de seed. Isso impede que um parente quase equivalente apareça no treino e torne o teste artificialmente fácil.

5 folds externos
medem desempenho
→
3 folds internos
escolhem configuração
→
Background completo
mede o rank real

Métrica principal por família	Resultado	Leitura prática
Percentil médio	**64,60%**	Em média, a família escondida ficou acima de 64,60% do background.
IC95% do percentil	**55,85%–72,85%**	Incerteza obtida por 4.000 reamostragens das famílias.
p do nulo	**0,0008**	O desempenho global é improvável sob ranking aleatório.
Recall@5%	**1/32 (3,13%)**	Uma família apareceu entre os 5% primeiros.
Recall@10%	**4/32 (12,50%)**	Quatro famílias apareceram entre os 10% primeiros.
p do Recall@10%	**0,2417**	O enriquecimento no topo ainda não foi significativo.
Recall@20%	**13/32 (40,63%)**	Treze famílias apareceram entre os 20% primeiros.

> **Defesa correta:** existe sinal global acima do nulo, mas ainda não há evidência robusta de concentração no top 10%. Percentil médio e Recall@10% respondem perguntas diferentes.

Baselines

Método	Percentil médio	Recall@10%
Ensemble PU maduro	64,60%	12,50%
Seed	53,08%	0,00%
Centroide k-mer maduro	51,35%	6,25%
Composição madura	63,54%	9,38%
Aleatório determinístico	54,34%	9,38%

Ablação: qual bloco de informação ajuda?

A ablação repete exatamente os mesmos folds, amostras PU e hiperparâmetros, alterando somente a representação da sequência madura. Assim, a comparação é pareada por família.

Representação	Percentil médio	Recall@10%
Core: k-mers globais, seed, tamanho e GC	60,63%	9,38%
Composição e entropia	55,79%	6,25%
K-mers posicionais	61,00%	6,25%
Motivos terminais 5p/3p	68,29%	28,13%
Representação completa	64,08%	18,75%

Leitura correta: motivos terminais superaram o core em 7,66 pontos percentuais (IC95% 1,23 a 14,96; p pareado nominal=0,0369; FDR BH=0,0738). É uma pista científica interessante, mas não permanece significativa a 5% após corrigir as quatro comparações. A configuração final foi escolhida somente nos folds internos e não pelo melhor número dessa tabela externa.

5. O que cada métrica representa

Métrica	Significado prático
Percentil médio	Posição relativa média dos marcadores escondidos no ranking.
Recall@X%	Fração das famílias escondidas recuperadas dentro dos X% primeiros.
IC95% bootstrap	Faixa de resultados plausíveis ao reamostrar as famílias observadas.
p do teste nulo	Frequência com que rankings aleatórios igualam ou superam o observado.
Mediana e IQR OOB	Posição típica e variação do candidato entre os 20 modelos em que ele não foi usado como contraste.
AUC OOF	Capacidade do candidato de ordenar doentes acima de saudáveis em amostras não usadas no treino daquele fold; 0,5 é acaso.
IC95% da AUC	Faixa aproximada de valores compatíveis com a AUC observada; intervalos acima de 0,5 sugerem separação interna.
FDR	Correção de Benjamini-Hochberg sobre 325 hipóteses de expressão únicas. Braços que usam a mesma coluna não são contados como testes independentes; valores no piso são apresentados como p<1e-16.
Cliff's delta	Tamanho de efeito não paramétrico: resume com que frequência a expressão de um grupo supera a do outro.
Hedges g	Diferença padronizada entre as médias, com correção para amostras pequenas.
Acurácia OOF	Proporção total de classificações corretas.
Precisão OOF	Entre amostras previstas como doentes, quantas realmente são doentes.
Sensibilidade	Entre os doentes, quantos foram identificados.
Especificidade	Entre os saudáveis, quantos foram identificados.
F1	Equilíbrio entre precisão e sensibilidade.
log2 fold-change	Magnitude e direção da diferença média de expressão entre doentes e saudáveis.

6. Como funciona o Modelo 2

Dos 2.613 candidatos, 611 possuem uma feature de expressão compatível. Para cada candidato, uma regressão logística univariada é avaliada por validação cruzada estratificada de 5 folds. Toda amostra recebe uma previsão out-of-fold de um modelo que não a viu durante o treino.

O que significa o confundimento da base interna?

Classe	Amostras	Origem observável
0 = saudável	1.339	1.339 IDs `GTEX-*`
1 = doente	1.339	1.339 UUIDs de arquivos de quantificação do CSV de doentes

Não há saudáveis vindos do CSV de doentes nem doentes vindos do GTEx. Logo, doença e origem mudam sempre juntas. Se um valor separa as classes, ele pode refletir câncer, origem/tecido/plataforma/processamento ou uma mistura desses efeitos. A base interna não permite calcular separadamente cada parcela.

> **Por que os 5 folds não resolvem?** Cada fold continua contendo a mesma regra: saudável = GTEx e doente = outro CSV. As previsões out-of-fold evitam que o modelo teste a própria amostra usada no treino, mas não criam o grupo cruzado que falta. A correção de lote também não sabe o que remover quando lote/origem e classe coincidem perfeitamente.

> **Proveniência:** o repositório comprova os controles GTEx pelos IDs. Para os doentes, há UUIDs de quantificação, mas não um manifesto clínico versionado que confirme cada amostra como TCGA-BRCA. A descrição rigorosa é “CSV original de doentes com IDs UUID de quantificação”.

70% AUC
força de separação entre doentes e saudáveis.

20% |log2FC|
magnitude da diferença de expressão.

10% detecção
presença de expressão nas amostras.

O ranking integrado combina 50% do percentil do Modelo 1 com 50% do score do Modelo 2.

Também são calculados cenários de sensibilidade com pesos 75%/25% e 25%/75%, além da fronteira de Pareto. A fronteira reúne candidatos para os quais não existe outro candidato simultaneamente melhor nos dois modelos. Se um nome permanece bem colocado nos três pesos, sua prioridade depende menos de uma escolha arbitrária de ponderação.

> **Ambiguidade de braços:** 552 dos 611 candidatos compartilham a mesma coluna de expressão com pelo menos outro candidato. Por isso, o FDR é calculado sobre 325 hipóteses únicas: 278 ficaram abaixo de 0,05 e correspondem a 531 candidatos. Esse número muito alto é evidência interna e reforça a suspeita de lote/fonte; não comprova 278 biomarcadores.

> **Consequência:** AUCs muito altas podem refletir fonte/processamento. As métricas do Modelo 2 descrevem associação dentro dessa montagem e não desempenho biológico ou clínico independente.

Top 5 integrado atual

1. **mir-32-3p** — 0,9965
2. **let-7f-5p** — 0,9833
3. **mir-32-5p** — 0,9734
4. **mir-95-5p** — 0,9317
5. **mir-200b-3p** — 0,9257

Como entrou a coorte externa?

A GSE73002 não ensinou novamente o modelo. Ela recebeu o ranking e a direção esperada congelados no commit `fab7197`. Antes de calcular AUCs, o protocolo, os hashes, a divisão TS e os critérios foram registrados na tag `pre-resultados-gse73002-v1`. O validador procurou colunas maduras exatas, separou proxies, calculou AUC, intervalo de confiança, tamanhos de efeito e FDR sem retreinar.

> **Formato desejado:** uma linha por paciente, identificador único, classe 1 para câncer de mama e 0 para controle, e colunas de expressão de muitos miRNAs maduros — idealmente distinguindo 5p e 3p. A tecnologia, o tipo de amostra e o pré-processamento devem ser informados.

7. Validação externa GSE73002

A análise principal utilizou somente a divisão de teste original da GSE73002: 1.206 amostras de soro de câncer de mama e 1.343 controles sem câncer, todas medidas na plataforma GPL18941. Os valores já estavam em log2 e foram usados sem aplicar outro logaritmo.

Ranking congelado
611 candidatos → **GSE73002 TS**
2.549 amostras → **579 exatos**
23 proxies → **AUC + IC + FDR**
sem retreino

Resultado principal	Valor	Leitura correta
Replicações maduras exatas	255/579	Direção concordante, limite inferior do IC95% da AUC acima de 0,5 e FDR abaixo de 0,05.
Exatas com AUC ≥ 0,60	254	Filtro descritivo de magnitude; não é limiar de uso clínico.
Exatas sem ambiguidade interna de braço	27	Subconjunto em que a evidência interna também distinguia melhor o braço maduro.
Top 10 congelado	7/10	Sete dos dez primeiros reproduziram como miRNA maduro exato.
Top 20 congelado	13/19 encontrados	Um candidato estava ausente; 13 dos 19 avaliáveis reproduziram.
Top 50 / Top 100	34/47 e 60/96	Há concentração de sinais reproduzidos nas faixas prioritárias.
Spearman score interno × AUC externa	0,0852	A ordenação global do score quase não acompanha a magnitude da AUC externa.

Controle negativo essencial: a média das 2.540 medidas de cada amostra separa câncer e controle com AUC 0,971; 95,67% dos miRNAs têm média maior no grupo câncer. Isso revela um deslocamento global de coorte/processamento. Portanto, não se deve afirmar que 255 miRNAs foram confirmados como biomarcadores específicos.

Sensibilidade pós-resultado

Para investigar esse deslocamento, foi subtraída de cada valor log2 a média dos 2.540 miRNAs da própria amostra. Essa análise foi marcada como pós-resultado e não substitui o desfecho principal. Após a centralização, 271 miRNAs exatos atenderam ao critério estatístico; 211 estavam também no resultado principal e 203 mantiveram AUC ≥ 0,60 nas duas análises. Nos 20 primeiros, os mesmos 13 sinais permaneceram robustos.

Hierarquia da evidência: os 211 ainda incluem candidatos cuja validação interna compartilhava uma feature entre braços 5p/3p. Exigindo também ausência dessa ambiguidade interna, o núcleo maduro estrito possui 22 candidatos; 21 mantêm AUC ≥ 0,60 nas duas análises. Para defender especificamente miRNA maduro, esse é o conjunto mais rigoroso.

Núcleo robusto do top 20 nas duas análises: mir-32-3p, let-7f-5p, mir-32-5p, mir-200b-3p, mir-29b-3p, mir-542-3p, mir-181b-3p, mir-582-5p, mir-182-5p, mir-141-3p, let-7a-3p, mir-142-3p e mir-106a-3p.

Dependência bibliográfica parcial: cinco dos 43 marcadores positivos foram extraídos do estudo de Shimomura ligado à GSE73002. Eles não fazem parte da lista de candidatos testada, mas influenciaram indiretamente o perfil sequencial aprendido. A limitação deve ser declarada.

Conclusão externa: a coorte apoia um subconjunto relevante — especialmente no topo —, mas não valida toda a lista nem demonstra aplicação clínica. Há 211 sinais concordantes entre as análises e um núcleo maduro estrito de 22 sem ambiguidade interna de braço.

8. Roteiro para a apresentação

"Primeiro, transformamos cada sequência madura em padrões globais e posicionais: k-mers, seed, composição e motivos das extremidades. Como temos positivos confiáveis, mas não negativos biológicos confirmados, usamos um ensemble Positive-Unlabeled com balanceamento por família. O Modelo 1 é testado escondendo famílias inteiras de seed. O Modelo 2 verifica associação interna de expressão e gera um ranking congelado. Por fim, aplicamos esse ranking sem retreino em 2.549 amostras externas de soro. Sete dos dez primeiros reproduziram, mas detectamos um deslocamento global e fizemos uma sensibilidade centrada. Duzentos e onze sinais coincidiram nas duas análises; o núcleo maduro mais rigoroso, sem ambiguidade interna de braço, tem 22 candidatos. Isso prioriza hipóteses e não confirma uso clínico."

Perguntas rápidas da banca

Por que k-mers?
Representam motivos locais sem exigir alinhamento e são adequados a um conjunto pequeno de positivos.

Por que retirar hairpin?
Para manter o foco na sequência madura e reduzir complexidade. A métrica principal não caiu após a retirada.

Por que não chamar os demais de negativos?
Ausência da lista positiva não comprova ausência de associação.

O que é confundimento na base interna?
Todos os controles são GTEx e todos os doentes vêm de outro CSV; doença e origem variam juntas. Assim, o Modelo 2 não separa completamente sinal biológico de sinal técnico.

Qual é a conclusão?
O Modelo 1 tem sinal global acima do nulo e a coorte externa reproduziu 7/10 do topo. Como existe deslocamento global na GSE73002 e baixa correlação do ranking completo, defendemos 211 sinais concordantes e, de forma mais rigorosa, 22 candidatos maduros sem ambiguidade interna de braço — não centenas de biomarcadores confirmados.

Limitações que devem ser declaradas

- 43 positivos e 32 famílias são uma amostra pequena.
- O conjunto não rotulado pode conter positivos desconhecidos.
- Recall@10% do Modelo 1 não foi significativo.
- No Modelo 2 interno, classe e fonte estão estruturalmente confundidas.
- 552/611 candidatos internos não têm expressão específica de braço.
- A GSE73002 tem forte deslocamento global entre classes e origem bibliográfica parcial de cinco marcadores.
- A correlação global entre score interno e AUC externa é baixa.

- Uma segunda coorte independente e validação laboratorial ainda são desejáveis.

Documento atualizado em 11/10/2026. Consulte `docs/METODOLOGIA_MODELOS_MIRNA.md`, `docs/PLANO_VALIDACAO_EXTERNA_GSE73002.md` e os relatórios GSE73002 em `reports/`.