TRABALHO DE CONCLUSÃO DE CURSO · GUIA PARA APRESENTAÇÃO

Como o pipeline de descoberta de miRNAs funciona

Da sequência **`AUGC...`** ao ranking integrado: k-mers, seed, precursor hairpin, estrutura, aprendizado Positive-Unlabeled e validação em pacientes.

43
biomarcadores positivos curados

2.613
candidatos ranqueados no Modelo 1

611
candidatos avaliados no Modelo 2

Versão metodológica vigente em 10/10/2026 · Projeto TCC-miRNA-Model

Como usar este guia

O objetivo é explicar o processo sem depender de fórmulas. Pense no projeto como duas peneiras sucessivas.



Ideia central: o Modelo 1 pergunta se um miRNA compartilha padrões moleculares com os positivos conhecidos. O Modelo 2 pergunta se sua expressão também está associada aos pacientes doentes.

Limite científico: o resultado é uma priorização computacional. Ele não confirma causalidade, diagnóstico, biomarcador clínico nem novidade na literatura.

Sumário

1. Os cinco termos biológicos fundamentais
2. Como a sequência vira k-mers
3. Como o Modelo 1 aprende
4. Como o ranking out-of-bag é produzido
5. Como o Modelo 1 é validado
6. Significado das métricas do Modelo 1
7. Como o Modelo 2 funciona
8. Significado das métricas do Modelo 2
9. Ranking integrado e interpretação científica
10. Roteiro curto para a banca

1. Os cinco termos biológicos fundamentais

Sequência madura

É a sequência curta do miRNA que já terminou seu processamento e atua na célula.

Ela normalmente possui cerca de duas dezenas de nucleotídeos e usa o alfabeto do RNA: **A, U, C e G**. É essa molécula madura que participa do reconhecimento de RNAs-alvo e da regulação da expressão gênica.

Exemplo ilustrativo: `AUGCUACUGAAC...`

No projeto: a sequência madura fornece k-mers, seed, comprimento e conteúdo GC.

Região seed

É uma pequena região inicial do miRNA maduro que tem grande influência sobre quais alvos ele reconhece.

De maneira simplificada, pode ser entendida como a parte mais importante da "chave" usada pelo miRNA para encontrar moléculas compatíveis.

Exemplo ilustrativo: `A` `UGCUAC` `UGAAC...`

MiRNAs com a mesma seed podem pertencer à mesma família funcional. Por isso, o projeto mantém famílias de seed inteiras juntas durante a validação, evitando que parentes quase duplicados sejam divididos entre treino e teste.

Sequência precursora hairpin

É a sequência maior que antecede o miRNA maduro e tende a se dobrar no formato de um grampo.

O miRNA maduro não surge isoladamente: ele é recortado de uma molécula precursora chamada pre-miRNA. Essa sequência contém dois braços e uma região de loop.

Precursor maior → Hairpin / grampo → Processamento celular → miRNA maduro

No projeto: o hairpin também é quebrado em k-mers. Isso permite observar padrões de biogênese que podem não estar visíveis apenas no fragmento maduro.

Características da estrutura do hairpin

São números que descrevem como o precursor está dobrado, e não apenas quais letras aparecem em sua sequência.

A estrutura é representada no formato dot-bracket. Parênteses representam bases pareadas e pontos representam bases livres:

```
((((...))))....((...))
```

O projeto registra fração pareada, fração livre, stems, loops, bulges, conteúdo GC e proporções de pares AU, GC e GU.

A execução atual usa um proxy Nussinov ponderado. Ele aproxima o pareamento, mas não calcula energia termodinâmica real. Portanto, o resultado atual não deve ser apresentado como MFE do RNAfold.

Peso de evidência científica

É a importância atribuída a cada marcador positivo conforme a força da evidência que motivou sua inclusão.

Um marcador sustentado por evidência mais forte influencia mais o aprendizado que um marcador incluído de forma exploratória:

Nível	Peso inicial	Interpretação
Alta	3	Maior confiança para orientar o padrão positivo.
Média	2	Evidência intermediária ou marcador do painel inicial.
Exploratória	1	Contribui, mas com menor influência.

Depois, esse peso é balanceado pelo número de positivos da mesma família de seed. Assim, famílias grandes não dominam o modelo apenas por terem mais membros.

2. Da sequência aos k-mers

K-mers são pequenos fragmentos consecutivos usados como um vocabulário molecular.

Considere a sequência ilustrativa **AUGCUA**:

Tamanho	Fragmentos gerados	O que capturam
k=2	`AU · UG · GC · CU · UA`	Padrões muito locais e frequentes.
k=3	`AUG · UGC · GCU · CUA`	Contextos um pouco mais específicos.
k=4	`AUGC · UGCU · GCUA`	Motivos locais mais detalhados.

A validação testou faixas de k-mers até k=7 e escolheu **k=2, 3 e 4**. Com apenas 43 positivos, fragmentos menores aparecem mais vezes e são menos propensos a memorizar sequências individuais.

> **Normalização:** as contagens viram frequências. Uma sequência maior não recebe score alto apenas porque produz mais fragmentos.

A impressão digital de um miRNA

Sequência madura
k-mers, seed, comprimento e conteúdo GC.

Precursor hairpin
k-mers do precursor e média entre loci equivalentes.

Estrutura
pareamento, stems, loops, bulges e tipos de pares.

Contexto científico
peso de evidência e balanceamento por família.

A configuração final aplica multiplicadores de bloco de 70% para madura/seed, 20% para hairpin e 10% para estrutura. Esses valores equilibram os blocos; não representam porcentagens biológicas da decisão.

Vocabulário final

Depois de remover k-mers excessivamente raros e preservar seed, composição e estrutura, o modelo final possui **650 features**. Cada miRNA vira uma linha de números nesse mesmo vocabulário.

3. Como o Modelo 1 aprende

Por que Positive-Unlabeled?

Temos 43 positivos conhecidos, mas não existe uma lista confiável de miRNAs comprovadamente irrelevantes ao câncer de mama. Ausência da lista positiva não é prova de negatividade.

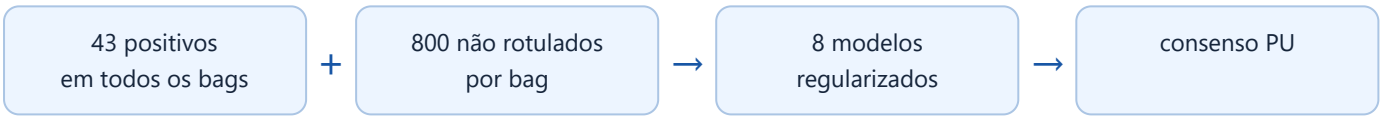
P — positivos
43 biomarcadores curados e ponderados.

U — não rotulados
podem conter irrelevantes, pouco estudados ou candidatos verdadeiros.

O conjunto U é usado somente como contraste temporário. A saída logística não é interpretada como probabilidade de câncer.

Bagging em oito modelos

São treinados oito modelos. Cada um recebe todos os positivos e uma amostra determinística diferente de 800 não rotulados.



Cada modelo aprende quais features aproximam uma sequência do perfil positivo e quais a aproximam do contraste utilizado naquele bag.

Pontuação out-of-bag

Um candidato não pode ser avaliado por um bag no qual ele foi usado como contraste. Ele é pontuado apenas pelos modelos que não o viram durante o treinamento.

> **Resultado:** cada candidato atual possui entre 2 e 8 modelos out-of-bag, e nenhum precisou de fallback. As features explicativas também são calculadas pelos mesmos modelos usados no score.

Do score bruto ao ranking

Os logits out-of-bag são usados para ordenar os 2.613 candidatos. A posição é convertida em percentil:

- **0,99** o candidato ficou acima de aproximadamente 99% da lista.
- **0,50** o candidato ficou aproximadamente no meio da lista.
- **0,05** o candidato ficou próximo da parte inferior.

> **Não dizer:** “score 0,99 significa 99% de chance de ser biomarcador”. O score é posição relativa, não probabilidade clínica.

4. Como o Modelo 1 é validado

A pergunta da validação é: o modelo consegue colocar no alto do ranking famílias positivas que nunca viu?

1. As 32 famílias de seed são divididas em cinco grupos externos.
2. Um grupo inteiro é escondido.
3. O modelo aprende somente com as famílias restantes.
4. Três grupos internos escolhem k-mers, pesos e regularização.
5. As famílias escondidas são comparadas com todo o background elegível.
6. O procedimento é repetido até todas as famílias terem sido escondidas.

> **Por família, não por marcador:** se parentes com a mesma seed fossem separados entre treino e teste, o modelo poderia reconhecer uma quase duplicata e o desempenho seria inflado.

Resultado atual do Modelo 1

Métrica	Resultado	Leitura prática
Percentil médio por família	**60,35%**	Uma família nunca vista ficou, em média, acima de 60,35% do background.
IC95% bootstrap	**51,79%–68,80%**	Faixa de incerteza ao reamostrar as 32 famílias.
Recall@1%	**0/32**	Nenhuma família chegou ao 1% mais alto.
Recall@5%	**0/32**	Nenhuma família chegou aos 5% mais altos.
Recall@10%	**3/32 = 9,38%**	Três famílias chegaram ao decil superior.
Recall@20%	**10/32 = 31,25%**	Dez famílias chegaram ao quinto superior.
Recall@10% por marcador	**5/43 = 11,63%**	Métrica secundária que conta marcadores, não famílias.

Teste contra ranking aleatório

Foram simulados 10.000 rankings aleatórios preservando o número de marcadores de cada família.

Teste	p-valor	Conclusão
Percentil médio	**0,0120**	Há sinal médio acima do nulo de ranking definido.
Recall@10%	**0,4723**	O enriquecimento específico no top 10% não foi significativo.

> *"O modelo apresenta sinal global acima do acaso, mas ainda não demonstrou concentração robusta das famílias positivas nas primeiras posições."*

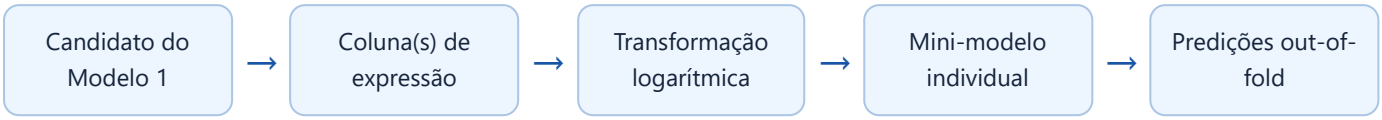
Comparação com baselines

Método	Percentil médio	Recall@10%
Ensemble PU completo	60,35%	9,38%
Similaridade de seed	53,08%	0%
Centroide k-mer maduro	50,90%	6,25%
Centroide k-mer hairpin	66,86%	9,38%
Ranking aleatório determinístico	54,34%	9,38%

> **Leitura honesta:** o baseline hairpin teve percentil observado maior que o ensemble. O precursor carrega sinal importante, e o modelo combinado ainda não provou superioridade geral.

5. Como o Modelo 2 funciona

Dos 2.613 candidatos, 611 possuem uma feature de expressão compatível no dataset de pacientes. A cobertura é **23,38%**.



Cada candidato é testado sozinho por uma regressão logística univariada. Se existirem várias colunas precursoras associadas, a expressão média é utilizada.

Validação cruzada em cinco folds

Os pacientes são separados de forma estratificada. Em cada rodada, quatro grupos treinam e o quinto é avaliado. No final, cada paciente possui uma predição produzida sem ter participado daquele treinamento.

> **Out-of-fold:** reduz o otimismo de medir o modelo nos mesmos pacientes usados para ajustar seus parâmetros. Ainda assim, não elimina lote, fonte ou outros fatores confundidores presentes em todos os folds.

Por que alguns braços compartilham resultados?

O ranking trabalha com miRNAs maduros, como 5p e 3p, mas a base de expressão frequentemente possui colunas no nível do precursor ou família. Assim, dois braços podem usar a mesma feature e receber as mesmas métricas no Modelo 2.

6. O que cada métrica do Modelo 2 representa

Métrica	Pergunta prática	Como interpretar
AUC	O candidato ordena doentes acima de saudáveis?	0,50 é semelhante ao acaso; valores próximos de 1 indicam separação interna muito forte.
Acurácia	Qual fração total recebeu a classe correta?	Mistura acertos em doentes e saudáveis.
Precisão	Entre os previstos como doentes, quantos eram doentes?	Alta precisão significa poucos falsos positivos.
Sensibilidade	Entre os doentes, quantos foram encontrados?	Alta sensibilidade significa poucos doentes perdidos.
Especificidade	Entre os saudáveis, quantos foram reconhecidos?	Alta especificidade significa poucos saudáveis classificados como doentes.
F1	Precisão e sensibilidade estão equilibradas?	Cai quando uma das duas é baixa.
TP	Quantos doentes foram corretamente previstos?	Verdadeiros positivos.
TN	Quantos saudáveis foram corretamente previstos?	Verdadeiros negativos.
FP	Quantos saudáveis foram chamados de doentes?	Falsos positivos.
FN	Quantos doentes foram chamados de saudáveis?	Falsos negativos.
Log2 fold-change	A expressão aumentou ou diminuiu nos doentes?	Positivo: maior nos doentes. Negativo: menor nos doentes. Módulo maior: diferença maior.
Média e mediana	Qual é o nível de expressão em cada classe?	A mediana é menos influenciada por valores extremos.
Presença > 0	Em quantos pacientes o miRNA foi detectado?	Ajuda a separar diferença de intensidade de diferença de presença.

Resultados descritivos atuais

28,97%
177 de 611 com AUC OOF ≥ 0,90.

42,23%
258 de 611 com AUC OOF ≥ 0,80.

23,90%
146 de 611 com precisão OOF ≥ 0,90.

23,38%
cobertura: 611 de 2.613 candidatos.

> **Importante:** essas porcentagens descrevem desempenho interno neste dataset. Não representam quantos biomarcadores foram confirmados. A origem/lote pode estar associada à classe e inflar a separação.

Score de validação em pacientes

O score resume três sinais: capacidade de separação out-of-fold, intensidade da diferença de expressão e diferença de detecção entre classes. A AUC recebe o maior peso. O score serve para ordenar candidatos e não é probabilidade clínica.

7. Ranking integrado

O ranking final combina igualmente:

50% Modelo 1
suporte relativo de sequência, seed, hairpin e estrutura.

50% Modelo 2
associação interna da expressão com os pacientes.

O peso 50/50 é uma escolha transparente de priorização, não um peso biológico aprendido.

Exemplos do efeito da segunda peneira

Candidato	Rank Modelo 1	AUC OOF	Rank integrado	Leitura
mir-590-3p	4	0,539	311	Forte padrão molecular, mas associação fraca nos pacientes.
mir-374a-3p	10	0,771	136	Associação moderada; perde prioridade.
mir-32-3p	14	≈1,000	1	Combina suporte alto nos dois modelos.
mir-369-3p	16	0,933	13	Mantém prioridade alta.
mir-95-5p	18	0,975	4	Sobe pela forte associação interna.

Top 5 integrado atual

1. **mir-32-3p** — score integrado 0,997488
2. **let-7f-5p** — score integrado 0,981814
3. **mir-32-5p** — score integrado 0,979877
4. **mir-95-5p** — score integrado 0,931170
5. **mir-26a-2-3p** — score integrado 0,918963

8. Como interpretar sem exagerar

Evite dizer	Prefira dizer
“60,35% de acurácia.”	“Percentil médio de 60,35% na validação externa por família.”
“Score 0,99 significa 99% de chance de câncer.”	“O candidato ficou acima de aproximadamente 99% da lista do Modelo 1.”
“O modelo validou 177 biomarcadores.”	“177 candidatos tiveram AUC OOF ≥ 0,90 na avaliação computacional interna.”
“p=0,012 prova que o modelo está correto.”	“O percentil médio foi improvável sob o nulo de ranking utilizado.”
“AUC 1 prova valor clínico.”	“A feature separou internamente as classes, mas pode refletir lote ou origem.”
“Descobrimos novos biomarcadores.”	“Priorizamos hipóteses que precisam de literatura, coorte externa e laboratório.”

Limitações que fortalecem a defesa quando reconhecidas

- 43 positivos e 32 famílias ainda são uma amostra pequena.
- O conjunto não rotulado pode conter positivos desconhecidos.
- A estrutura atual é proxy Nussinov, não termodinâmica RNAfold.
- O baseline hairpin teve percentil observado maior que o ensemble.
- Recall@10% não foi significativo.
- O Modelo 2 pode capturar lote ou origem das amostras.
- O ranking integrado 50/50 é uma regra heurística.
- Novidade científica exige revisão sistemática da literatura.
- Confirmação exige coorte externa e validação laboratorial.

9. Roteiro curto para a apresentação

> *"Primeiro, representamos cada miRNA por pequenos padrões chamados k-mers, extraídos tanto da sequência madura quanto do precursor hairpin. Também incluímos a seed, composição e características da estrutura secundária. Como temos positivos confiáveis, mas não negativos biológicos, usamos um ensemble Positive-Unlabeled com balanceamento por família. Cada candidato é pontuado somente por modelos out-of-bag que não o utilizaram como contraste. O Modelo 1 gera um ranking molecular e é avaliado escondendo famílias inteiras de seed. Depois, o Modelo 2 testa os candidatos que possuem expressão disponível e verifica, por predições out-of-fold, se sua expressão está associada a doentes e saudáveis. O ranking integrado combina as duas evidências e serve para priorizar hipóteses, não para confirmar biomarcadores."*

Perguntas rápidas da banca

Por que k-mers?
Representam motivos locais sem exigir alinhamento e funcionam melhor que modelos muito complexos quando há poucos positivos.

Por que hairpin?
O precursor pode carregar informação de biogênese e estrutura ausente no fragmento maduro.

Por que não chamar os outros de negativos?
Porque ausência da lista positiva não comprova ausência de associação.

Por que separar por família de seed?
Para impedir vazamento entre parentes quase equivalentes.

Qual é a principal conclusão?
Há sinal molecular global acima do nulo, mas o enriquecimento no top 10% ainda não é robusto; o Modelo 2 acrescenta uma segunda evidência interna que precisa de validação externa.

Arquivos para consulta

- `docs/METODOLOGIA_MODELOS_MIRNA.md`
- `reports/modelo_mirna_candidate_discovery_report.txt`
- `reports/modelo_mirna_patient_candidate_validation_report.txt`
- `reports/auditoria_pipeline_descoberta_mirna.txt`
- `reports/mirna_rankings_dashboard.html`

Documento gerado a partir da implementação vigente do repositório em 10/10/2026. Os números devem ser atualizados se o pipeline for reexecutado com novos dados, RNAfold ou outra configuração.