TRABALHO DE CONCLUSÃO DE CURSO · GUIA PARA APRESENTAÇÃO

Como o pipeline de descoberta de miRNAs funciona

Da sequência madura **`AUGC...`** ao ranking integrado: k-mers, seed, aprendizado Positive-Unlabeled e validação em pacientes.

43
miRNAs positivos curados

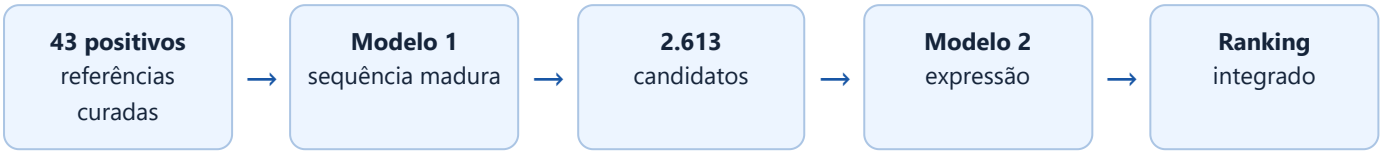
2.613
candidatos no Modelo 1

611
avaliados no Modelo 2

Versão vigente em 10/10/2026 · Modelo centrado na sequência madura · TCC-miRNA-Model

1. Visão geral: duas perguntas, dois modelos

O projeto funciona como duas peneiras sucessivas. A primeira procura semelhança molecular com marcadores conhecidos; a segunda verifica associação de expressão nos pacientes.



> **Resposta curta para a banca:** o Modelo 1 prioriza candidatos por padrões da sequência madura; o Modelo 2 verifica se a expressão disponível separa doentes e saudáveis. Nenhum dos dois confirma sozinho um biomarcador.

Por que o hairpin não aparece mais?

O hairpin é biologicamente parte da formação do miRNA, mas foi retirado do pipeline para reduzir complexidade e manter a pergunta do TCC centrada no miRNA maduro. O percentil médio passou de 60,35% para 60,55% e o Recall@10% permaneceu em 9,38%. A mudança é pequena e não prova melhora estatística, mas mostra que a simplificação não prejudicou a métrica principal observada.

> **Escopo atual:** k-mers, seed, comprimento e fração GC da sequência madura. Hairpin, estrutura secundária e MFE não entram no modelo.

2. Os termos essenciais

Sequência madura
Pequeno RNA funcional após o processamento do precursor. É a sequência usada pelo Modelo 1.

Seed
Posições 2 a 8 da sequência madura. É importante para o reconhecimento de alvos e para agrupar miRNAs relacionados.

k-mer
Fragmento de comprimento k extraído da sequência. Ex.: para k=3, `AUG`, `UGC` e `GCU`.

Fração GC
Proporção de G e C na sequência madura. Resume sua composição.

Peso de evidência
Importância dada a cada positivo segundo a curadoria: alta=3, média=2, exploratória=1.

Família de seed
Grupo de marcadores com a mesma seed. É a unidade principal da validação.

Exemplo de quebra em k-mers

A U G C U A A C G U A

k	Fragmentos sucessivos	O que representa
2	`AU`, `UG`, `GC`, ...	Padrões muito locais e frequentes.
3	`AUG`, `UGC`, `GCU`, ...	Contexto local um pouco maior.
4	`AUGC`, `UGCU`, ...	Motivos mais específicos.

As contagens são normalizadas pelo total de fragmentos, evitando que uma sequência pareça mais importante apenas por ser um pouco maior. A configuração final usa k=2,3,4.

3. Como o Modelo 1 aprende

1. Carrega os 43 miRNAs positivos e suas sequências maduras.
2. Converte cada sequência em um vetor de k-mers, seed, comprimento e fração GC.
3. Aplica o peso de evidência e divide o peso entre positivos da mesma família de seed.
4. Usa os demais miRNAs como conjunto *não rotulado*, e não como negativos biológicos.
5. Treina 8 modelos com amostras diferentes de 800 não rotulados.
6. Pontua cada candidato somente pelos modelos que não o usaram como contraste: pontuação out-of-bag.
7. Converte o logit em percentil dentro dos 2.613 candidatos e produz o ranking.

> **Por que Positive-Unlabeled?** Estar fora da lista dos 43 não significa ser biologicamente negativo. Alguns não rotulados podem ser candidatos verdadeiros ainda pouco estudados.

O que significa out-of-bag?

Se um candidato entrou como contraste temporário em determinado bag, aquele modelo não pode pontuá-lo. Ele recebe a média apenas dos bags em que ficou de fora. Isso reduz a penalização artificial causada pelo próprio processo PU.

O score é probabilidade de câncer?

Não. `score_modelo_sequencial` é uma posição relativa: 0,99 indica que o candidato ficou acima de aproximadamente 99% do universo avaliado. A probabilidade PU bruta também é apenas uma saída contrastiva interna.

4. Como testamos se o Modelo 1 generaliza

A avaliação esconde famílias inteiras de seed. Isso impede que um parente quase equivalente apareça no treino e torne o teste artificialmente fácil.

5 folds externos
medem desempenho
→
3 folds internos
escolhem configuração
→
Background completo
mede o rank real

Métrica principal por família	Resultado	Leitura prática
Percentil médio	**60,55%**	Em média, a família escondida ficou acima de 60,55% do background.
IC95% do percentil	**51,87%–69,02%**	Incerteza obtida por 4.000 reamostragens das famílias.
p do nulo	**0,0111**	O desempenho global é improvável sob ranking aleatório.
Recall@5%	**1/32 (3,13%)**	Uma família apareceu entre os 5% primeiros.
Recall@10%	**3/32 (9,38%)**	Três famílias apareceram entre os 10% primeiros.
p do Recall@10%	**0,4723**	O enriquecimento no topo não foi significativo.
Recall@20%	**9/32 (28,13%)**	Nove famílias apareceram entre os 20% primeiros.

> **Defesa correta:** existe sinal global acima do nulo, mas ainda não há evidência robusta de concentração no top 10%. Percentil médio e Recall@10% respondem perguntas diferentes.

Baselines

Método	Percentil médio	Recall@10%
Ensemble PU maduro	60,55%	9,38%
Seed	53,08%	0,00%
Centroide k-mer maduro	51,19%	6,25%
Composição madura	63,54%	9,38%
Aleatório determinístico	54,34%	9,38%

5. O que cada métrica representa

Métrica	Significado prático
Percentil médio	Posição relativa média dos marcadores escondidos no ranking.
Recall@X%	Fração das famílias escondidas recuperadas dentro dos X% primeiros.
IC95% bootstrap	Faixa de resultados plausíveis ao reamostrar as famílias observadas.
p do teste nulo	Frequência com que rankings aleatórios igualam ou superam o observado.
AUC OOF	Capacidade do candidato de ordenar doentes acima de saudáveis em amostras não usadas no treino daquele fold; 0,5 é acaso.
Acurácia OOF	Proporção total de classificações corretas.
Precisão OOF	Entre amostras previstas como doentes, quantas realmente são doentes.
Sensibilidade	Entre os doentes, quantos foram identificados.
Especificidade	Entre os saudáveis, quantos foram identificados.
F1	Equilíbrio entre precisão e sensibilidade.
log2 fold-change	Magnitude e direção da diferença média de expressão entre doentes e saudáveis.

6. Como funciona o Modelo 2

Dos 2.613 candidatos, 611 possuem uma feature de expressão compatível. Para cada candidato, uma regressão logística univariada é avaliada por validação cruzada estratificada de 5 folds. Toda amostra recebe uma previsão out-of-fold de um modelo que não a viu durante o treino.

70% AUC
força de separação entre doentes e saudáveis.

20% |log2FC|
magnitude da diferença de expressão.

10% detecção
presença de expressão nas amostras.

O ranking integrado combina 50% do percentil do Modelo 1 com 50% do score do Modelo 2.

> **Limite importante:** AUCs muito altas podem refletir diferença de fonte ou lote entre doentes e saudáveis. Validação cruzada interna não corrige esse confundimento.

Top 5 integrado atual

1. **mir-32-3p** — 0,9973
2. **let-7f-5p** — 0,9818
3. **mir-32-5p** — 0,9774
4. **mir-95-5p** — 0,9321
5. **mir-200b-3p** — 0,9253

7. Roteiro para a apresentação

> *"Primeiro, transformamos cada sequência madura em pequenos padrões chamados k-mers. Também representamos a seed, o comprimento e a composição GC. Como temos positivos confiáveis, mas não negativos biológicos confirmados, usamos um ensemble Positive-Unlabeled com balanceamento por família. Cada candidato é pontuado somente por modelos out-of-bag que não o usaram como contraste. O Modelo 1 é testado escondendo famílias inteiras de seed. Depois, o Modelo 2 usa predições out-of-fold para verificar se a expressão disponível está associada a doentes e saudáveis. O ranking integrado combina essas duas evidências e prioriza hipóteses, sem confirmar biomarcadores."*

Perguntas rápidas da banca

Por que k-mers?
Representam motivos locais sem exigir alinhamento e são adequados a um conjunto pequeno de positivos.

Por que retirar hairpin?
Para manter o foco na sequência madura e reduzir complexidade. A métrica principal não caiu após a retirada.

Por que não chamar os demais de negativos?
Ausência da lista positiva não comprova ausência de associação.

Qual é a conclusão?
Há sinal global acima do nulo, mas o top 10% ainda não é robusto. Os resultados são candidatos para investigação externa.

Limitações que devem ser declaradas

- 43 positivos e 32 famílias são uma amostra pequena.
- O conjunto não rotulado pode conter positivos desconhecidos.
- Recall@10% não foi significativo.
- O baseline de composição madura teve percentil observado maior que o ensemble.
- O Modelo 2 pode capturar lote ou origem.
- O dataset pode não distinguir 5p de 3p.
- Confirmação exige coorte externa e validação laboratorial.

Documento gerado a partir da implementação vigente em 10/10/2026. Consulte `docs/METODOLOGIA_MODELOS_MIRNA.md` e `reports/auditoria_pipeline_descoberta_mirna.txt`.