TRABALHO DE CONCLUSÃO DE CURSO · GUIA PARA APRESENTAÇÃO

Como o pipeline de descoberta de miRNAs funciona

Da sequência madura **`AUGC...`** ao ranking integrado: k-mers, seed, aprendizado Positive-Unlabeled e validação em pacientes.

43
miRNAs positivos curados

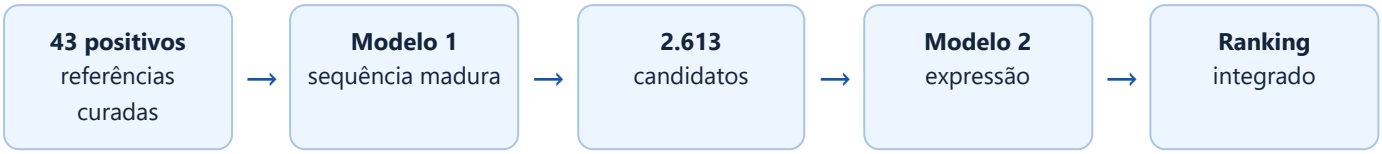
2.613
candidatos no Modelo 1

611
avaliados no Modelo 2

Versão vigente em 10/10/2026 · Modelo centrado na sequência madura · TCC-miRNA-Model

1. Visão geral: duas perguntas, dois modelos

O projeto funciona como duas peneiras sucessivas. A primeira procura semelhança molecular com marcadores conhecidos; a segunda verifica associação de expressão nos pacientes.



> **Resposta curta para a banca:** o Modelo 1 prioriza candidatos por padrões da sequência madura; o Modelo 2 verifica se a expressão disponível separa doentes e saudáveis. Nenhum dos dois confirma sozinho um biomarcador.

Por que o hairpin não aparece mais?

O hairpin é biologicamente parte da formação do miRNA, mas foi retirado do pipeline para reduzir complexidade e manter a pergunta do TCC centrada no miRNA maduro. A primeira versão madura-only preservou o desempenho observado. Depois, novas representações exclusivamente maduras elevaram o percentil médio externo de 60,55% para 64,60%. Esse ganho é promissor, mas continua sendo uma comparação interna e não substitui uma coorte externa.

> **Escopo atual:** k-mers globais e posicionais, seed, comprimento, composição, entropia e motivos das extremidades 5p/3p da sequência madura. Hairpin, estrutura secundária e MFE não entram no modelo.

2. Os termos essenciais

Sequência madura
Pequeno RNA funcional após o processamento do precursor. É a sequência usada pelo Modelo 1.

Seed
Posições 2 a 8 da sequência madura. É importante para o reconhecimento de alvos e para agrupar miRNAs relacionados.

k-mer
Fragmento de comprimento k extraído da sequência. Ex.: para k=3, `AUG`, `UGC` e `GCU`.

Fração GC
Proporção de G e C na sequência madura. Resume sua composição.

Peso de evidência
Importância dada a cada positivo segundo a curadoria: alta=3, média=2, exploratória=1.

Família de seed
Grupo de marcadores com a mesma seed. É a unidade principal da validação.

Exemplo de quebra em k-mers

A U G C U A A C G U A

k	Fragmentos sucessivos	O que representa
2	`AU`, `UG`, `GC`, ...	Padrões muito locais e frequentes.
3	`AUG`, `UGC`, `GCU`, ...	Contexto local um pouco maior.
4	`AUGC`, `UGCU`, ...	Motivos mais específicos.

As contagens são normalizadas pelo total de fragmentos, evitando que uma sequência pareça mais importante apenas por ser um pouco maior. A configuração final usa k=2,3,4 e separa os motivos encontrados no começo, centro e fim da sequência. Essa posição importa porque o mesmo fragmento pode ter papéis diferentes dependendo de onde aparece.

Outras pistas extraídas do miRNA maduro

Composição
Frações de A, U, C e G e entropia, que resumem diversidade e equilíbrio da sequência.

Posição
K-mers separados nas regiões 5p, central e 3p, preservando onde cada padrão ocorreu.

Extremidades
Motivos exatos de 2, 3 e 4 bases no início e no fim do miRNA maduro.

3. Como o Modelo 1 aprende

1. Carrega os 43 miRNAs positivos e suas sequências maduras.
2. Converte cada sequência em um vetor com k-mers, seed, comprimento, composição, entropia, posição e motivos terminais.
3. Aplica o peso de evidência e divide o peso entre positivos da mesma família de seed.
4. Usa os demais miRNAs como conjunto *não rotulado*, e não como negativos biológicos.
5. Compara oito configurações dentro dos folds internos, sem consultar o teste externo.
6. Treina um ensemble final de 20 modelos, cada um com uma amostra diferente de 800 não rotulados.
7. Pontua cada candidato somente pelos modelos que não o usaram como contraste: pontuação out-of-bag.
8. Converte o logit em percentil dentro dos 2.613 candidatos e produz o ranking.

> **Por que Positive-Unlabeled?** Estar fora da lista dos 43 não significa ser biologicamente negativo. Alguns não rotulados podem ser candidatos verdadeiros ainda pouco estudados.

O que significa out-of-bag?

Se um candidato entrou como contraste temporário em determinado bag, aquele modelo não pode pontuá-lo. Ele recebe a média apenas dos bags em que ficou de fora. Isso reduz a penalização artificial causada pelo próprio processo PU.

Como medimos a estabilidade do ranking?

Além do percentil final, o pipeline registra, para cada candidato, a mediana, os quartis e a frequência com que ele aparece nos top 1%, 5%, 10% e 20% entre os modelos em que estava out-of-bag. Um candidato alto e consistente é mais confiável que outro que chega à mesma média por poucos resultados extremos.

O score é probabilidade de câncer?

Não. `score_modelo_sequencial` é uma posição relativa: 0,99 indica que o candidato ficou acima de aproximadamente 99% do universo avaliado. A probabilidade PU bruta também é apenas uma saída contrastiva interna.

4. Como testamos se o Modelo 1 generaliza

A avaliação esconde famílias inteiras de seed. Isso impede que um parente quase equivalente apareça no treino e torne o teste artificialmente fácil.

5 folds externos
medem desempenho
→
3 folds internos
escolhem configuração
→
Background completo
mede o rank real

Métrica principal por família	Resultado	Leitura prática
Percentil médio	**64,60%**	Em média, a família escondida ficou acima de 64,60% do background.
IC95% do percentil	**55,85%–72,85%**	Incerteza obtida por 4.000 reamostragens das famílias.
p do nulo	**0,0008**	O desempenho global é improvável sob ranking aleatório.
Recall@5%	**1/32 (3,13%)**	Uma família apareceu entre os 5% primeiros.
Recall@10%	**4/32 (12,50%)**	Quatro famílias apareceram entre os 10% primeiros.
p do Recall@10%	**0,2417**	O enriquecimento no topo ainda não foi significativo.
Recall@20%	**13/32 (40,63%)**	Treze famílias apareceram entre os 20% primeiros.

> **Defesa correta:** existe sinal global acima do nulo, mas ainda não há evidência robusta de concentração no top 10%. Percentil médio e Recall@10% respondem perguntas diferentes.

Baselines

Método	Percentil médio	Recall@10%
Ensemble PU maduro	64,60%	12,50%
Seed	53,08%	0,00%
Centroide k-mer maduro	51,35%	6,25%
Composição madura	63,54%	9,38%
Aleatório determinístico	54,34%	9,38%

Ablação: qual bloco de informação ajuda?

A ablação repete exatamente os mesmos folds, amostras PU e hiperparâmetros, alterando somente a representação da sequência madura. Assim, a comparação é pareada por família.

Representação	Percentil médio	Recall@10%
Core: k-mers globais, seed, tamanho e GC	60,63%	9,38%
Composição e entropia	55,79%	6,25%
K-mers posicionais	61,00%	6,25%
Motivos terminais 5p/3p	68,29%	28,13%
Representação completa	64,08%	18,75%

Leitura correta: motivos terminais superaram o core em 7,66 pontos percentuais (IC95% 1,23 a 14,96; p pareado nominal=0,0369; FDR BH=0,0738). É uma pista científica interessante, mas não permanece significativa a 5% após corrigir as quatro comparações. A configuração final foi escolhida somente nos folds internos e não pelo melhor número dessa tabela externa.

5. O que cada métrica representa

Métrica	Significado prático
Percentil médio	Posição relativa média dos marcadores escondidos no ranking.
Recall@X%	Fração das famílias escondidas recuperadas dentro dos X% primeiros.
IC95% bootstrap	Faixa de resultados plausíveis ao reamostrar as famílias observadas.
p do teste nulo	Frequência com que rankings aleatórios igualam ou superam o observado.
Mediana e IQR OOB	Posição típica e variação do candidato entre os 20 modelos em que ele não foi usado como contraste.
AUC OOF	Capacidade do candidato de ordenar doentes acima de saudáveis em amostras não usadas no treino daquele fold; 0,5 é acaso.
IC95% da AUC	Faixa aproximada de valores compatíveis com a AUC observada; intervalos acima de 0,5 sugerem separação interna.
FDR	Correção de Benjamini-Hochberg sobre 325 hipóteses de expressão únicas. Braços que usam a mesma coluna não são contados como testes independentes; valores no piso são apresentados como p<1e-16.
Cliff's delta	Tamanho de efeito não paramétrico: resume com que frequência a expressão de um grupo supera a do outro.
Hedges g	Diferença padronizada entre as médias, com correção para amostras pequenas.
Acurácia OOF	Proporção total de classificações corretas.
Precisão OOF	Entre amostras previstas como doentes, quantas realmente são doentes.
Sensibilidade	Entre os doentes, quantos foram identificados.
Especificidade	Entre os saudáveis, quantos foram identificados.
F1	Equilíbrio entre precisão e sensibilidade.
log2 fold-change	Magnitude e direção da diferença média de expressão entre doentes e saudáveis.

6. Como funciona o Modelo 2

Dos 2.613 candidatos, 611 possuem uma feature de expressão compatível. Para cada candidato, uma regressão logística univariada é avaliada por validação cruzada estratificada de 5 folds. Toda amostra recebe uma previsão out-of-fold de um modelo que não a viu durante o treino.

70% AUC
força de separação entre doentes e saudáveis.

20% |log2FC|
magnitude da diferença de expressão.

10% detecção
presença de expressão nas amostras.

O ranking integrado combina 50% do percentil do Modelo 1 com 50% do score do Modelo 2.

Também são calculados cenários de sensibilidade com pesos 75%/25% e 25%/75%, além da fronteira de Pareto. A fronteira reúne candidatos para os quais não existe outro candidato simultaneamente melhor nos dois modelos. Se um nome permanece bem colocado nos três pesos, sua prioridade depende menos de uma escolha arbitrária de ponderação.

Ambiguidade de braços: 552 dos 611 candidatos compartilham a mesma coluna de expressão com pelo menos outro candidato. Por isso, o FDR é calculado sobre 325 hipóteses únicas: 278 ficaram abaixo de 0,05 e correspondem a 531 candidatos. Esse número muito alto é evidência interna e reforça a suspeita de lote/fonte; não comprova 278 biomarcadores.

Limite importante: AUCs muito altas podem refletir diferença de fonte ou lote entre doentes e saudáveis. Validação cruzada interna não corrige esse confundimento.

Top 5 integrado atual

1. **mir-32-3p** — 0,9965
2. **let-7f-5p** — 0,9833
3. **mir-32-5p** — 0,9734
4. **mir-95-5p** — 0,9317
5. **mir-200b-3p** — 0,9257

Como entra a futura coorte externa?

A nova base não serve para ensinar novamente o modelo. Ela recebe o ranking e a direção esperada já congelados. O validador procura as colunas maduras exatas, marca separadamente aproximações por família/precursor, calcula AUC e intervalo de confiança externos, corrige os testes por FDR e verifica se a direção do efeito se repete. Um sinal só recebe o rótulo de reproduzido com ao menos 10 amostras por classe, direção concordante, limite inferior do IC95% acima de 0,5 e FDR abaixo de 0,05. Isso testa transportabilidade em pacientes independentes.

Formato desejado: uma linha por paciente, identificador único, classe 1 para câncer de mama e 0 para controle, e colunas de expressão de muitos miRNAs maduros — idealmente distinguindo 5p e 3p. A tecnologia, o tipo de amostra e o pré-processamento devem ser informados.

7. Roteiro para a apresentação

> *"Primeiro, transformamos cada sequência madura em padrões globais e posicionais: k-mers, seed, composição e motivos das extremidades. Como temos positivos confiáveis, mas não negativos biológicos confirmados, usamos um ensemble Positive-Unlabeled com balanceamento por família. Cada candidato é pontuado somente por modelos out-of-bag que não o usaram como contraste, e sua estabilidade é medida entre 20 bags. O Modelo 1 é testado escondendo famílias inteiras de seed. Depois, o Modelo 2 usa predições out-of-fold, correção FDR e tamanhos de efeito para verificar associação com doentes e saudáveis. O ranking integrado combina essas evidências e prioriza hipóteses, sem confirmar biomarcadores."*

Perguntas rápidas da banca

Por que k-mers?
Representam motivos locais sem exigir alinhamento e são adequados a um conjunto pequeno de positivos.

Por que retirar hairpin?
Para manter o foco na sequência madura e reduzir complexidade. A métrica principal não caiu após a retirada.

Por que não chamar os demais de negativos?
Ausência da lista positiva não comprova ausência de associação.

Qual é a conclusão?
Há sinal global acima do nulo, mas o enriquecimento do top 10% ainda não é significativo. Os resultados são candidatos priorizados para investigação externa.

Limitações que devem ser declaradas

- 43 positivos e 32 famílias são uma amostra pequena.
- O conjunto não rotulado pode conter positivos desconhecidos.
- Recall@10% não foi significativo.
- O ganho de motivos terminais na ablação é exploratório e não foi usado para escolher o modelo olhando o teste externo.
- O Modelo 2 pode capturar lote ou origem.
- 552/611 candidatos do Modelo 2 não têm expressão específica de braço.
- Confirmação exige coorte externa e validação laboratorial.

Documento gerado a partir da implementação vigente em 10/10/2026. Consulte `docs/METODOLOGIA_MODELOS_MIRNA.md` e `reports/auditoria_pipeline_descoberta_mirna.txt`.