UNIVERSIDADE POSITIVO
BACHARELADO EM ENGENHARIA DE SOFTWARE

BRIAN CRISTIAN CAVALHEIRO
GABRIEL RIBEIRO BATISTA
HENRY KENZO KARASAWA
LEONARDO SILVA RABELLO
VITOR GABRIEL AGNER

DESCOBERTA E PRIORIZAÇÃO COMPUTACIONAL DE CANDIDATOS A BIOMARCADORES DE MICRORNA ASSOCIADOS AO CÂNCER DE MAMA

CURITIBA
2026

BRIAN CRISTIAN CAVALHEIRO
GABRIEL RIBEIRO BATISTA
HENRY KENZO KARASAWA
LEONARDO SILVA RABELLO
VITOR GABRIEL AGNER

DESCOBERTA E PRIORIZAÇÃO COMPUTACIONAL DE CANDIDATOS A BIOMARCADORES DE MICRORNA ASSOCIADOS AO CÂNCER DE MAMA

Trabalho apresentado como requisito parcial na disciplina de Trabalho de Conclusão de Curso I da Universidade Positivo para obtenção do grau de Bacharel em Engenharia de Software.

Orientador: Prof. Aryel Marlus Repula de Oliveira

CURITIBA
2026

RESUMO

Este trabalho desenvolve um fluxo computacional exploratório para descobrir e priorizar microRNAs (miRNAs) maduros associados ao câncer de mama. O produto científico é uma lista ordenada de hipóteses para orientar pesquisas futuras, e não uma ferramenta de diagnóstico, pré-diagnóstico, rastreamento individual ou decisão clínica. O fluxo começa com 43 miRNAs positivos conhecidos. O Modelo 1 aprende padrões de suas sequências maduras e ranqueia 2.613 miRNAs não rotulados. Em seguida, o Modelo 2 realiza uma triagem interna de associação de expressão nos 611 candidatos presentes na base interna e combina essa evidência com a lista ordenada do Modelo 1. A lista ordenada integrada é congelada e avaliada, sem retreinamento, na coorte externa de soro GEO GSE73002. O Modelo 1 apresentou sinal global acima do acaso, mas desempenho próximo ao de uma linha de base simples de composição e sem enriquecimento significativo no primeiro décimo da lista ordenada. Na avaliação externa, 579 candidatos tiveram correspondência madura exata; 211 sinais permaneceram concordantes na análise principal e na análise de sensibilidade centrada. Um subconjunto conservador de 22 candidatos também não apresentou ambiguidade interna entre os braços 5p e 3p. O forte deslocamento global da coorte, o confundimento entre classe e fonte na base interna e a baixa correlação entre a ordem da lista e a AUC externa limitam a interpretação. Os resultados reduzem o espaço de busca e sustentam hipóteses computacionais, mas não confirmam biomarcadores nem demonstram utilidade clínica.

Palavras-chave: microRNA; câncer de mama; geração de hipóteses; priorização de candidatos; validação externa.

ABSTRACT

This study develops an exploratory computational pipeline to discover and prioritize mature microRNAs (miRNAs) associated with breast cancer. Its scientific product is a ranked set of hypotheses for future research, not a diagnostic, pre-diagnostic, individual screening, or clinical decision tool. The workflow starts from 43 known positive miRNAs. Model 1 learns patterns from their mature sequences and ranks 2,613 unlabeled miRNAs. Model 2 then performs an internal expression-association screen on the 611 candidates available in the internal dataset and combines this evidence with the sequence ranking. The integrated ranking is frozen and evaluated without retraining in the GEO GSE73002 external serum cohort. Model 1 showed a global signal above chance, but performed close to a simple composition baseline and did not show significant enrichment in the top decile of the ranking. In the external evaluation, 579 candidates had exact mature-miRNA matches; 211 signals were concordant in both the primary and sample-centered sensitivity analyses. A conservative subset of 22 candidates also lacked internal 5p/3p arm ambiguity. A strong cohort-wide shift, confounding between class and data source in the internal dataset, and the low correlation between ranking score and external AUC limit interpretation. The findings narrow the search space and support computational hypotheses, but they neither confirm biomarkers nor demonstrate clinical utility.

Keywords: microRNA; breast cancer; hypothesis generation; candidate prioritization; external validation.

LISTA DE QUADROS

Quadro 1 — Marcadores positivos usados no treinamento do Modelo 1 20

LISTA DE TABELAS

Tabela 1 — Síntese do funil de geração de hipóteses 28
Tabela 2 — Resultados essenciais do Modelo 1 28
Tabela 3 — Candidatos selecionados para interpretação 29

LISTA DE ABREVIATURAS E SIGLAS

AUC	Área sob a curva ROC (Area Under the Curve)
CEP	Comitê de Ética em Pesquisa
CNS	Conselho Nacional de Saúde
Conep	Comissão Nacional de Ética em Pesquisa
CSV	Valores separados por vírgula (Comma-Separated Values)
FDR	Taxa de descobertas falsas (False Discovery Rate)
GC	Guanina e citosina
GDC	Genomic Data Commons
GEO	Gene Expression Omnibus
GSM	Identificador de amostra do GEO (GEO Sample)
GTEx	Genotype-Tissue Expression
HMDD	Human microRNA Disease Database
HTML	Linguagem de marcação de hipertexto (HyperText Markup Language)
IC95%	Intervalo de confiança de 95%
JSON	Notação de objetos JavaScript (JavaScript Object Notation)
log2FC	Logaritmo na base 2 da razão entre médias (log2 fold change)
miRNA	MicroRNA
NCBI	National Center for Biotechnology Information
RNA	Ácido ribonucleico
ROC	Receiver Operating Characteristic
RPM	Leituras por milhão (Reads Per Million)
TCC	Trabalho de Conclusão de Curso
TPM	Transcritos por milhão (Transcripts Per Million)

SUMÁRIO

1 INTRODUÇÃO 10

1.1 JUSTIFICATIVA 11

1.2 OBJETIVOS 12

1.2.1 Objetivo geral 12

1.2.2 Objetivos específicos 12

2 REVISÃO BIBLIOGRÁFICA 14

2.1 TRABALHOS RELACIONADOS 14

2.2 TIPO E OBJETO DE PESQUISA 16

2.3 POPULAÇÃO OU AMOSTRA DE ESTUDO 17

2.3.1 Critérios de inclusão 18

2.3.2 Critérios de exclusão 18

3 DESCRIÇÃO DO PROCESSO DE COLETA DE DADOS 20

3.1 FONTES E SELEÇÃO DOS DADOS 20

3.2 INTEGRIDADE E RASTREABILIDADE DOS DADOS 23

4 DESCRIÇÃO DO PROCESSO DE ANÁLISE DE DADOS 24

4.1 VISÃO GERAL DO FUNIL 24

4.2 MODELO 1 — PRIORIZAÇÃO PELA SEQUÊNCIA MADURA 24

4.3 MODELO 2 — TRIAGEM INTERNA DE ASSOCIAÇÃO DE EXPRESSÃO 25

4.4 INTEGRAÇÃO E AVALIAÇÃO EXTERNA 25

4.5 INTERPRETAÇÃO DAS MÉTRICAS 26

4.6 ALGORITMOS, FERRAMENTAS E BIBLIOTECAS 26

5 RESULTADOS 28

5.1 RESULTADO GERAL DO FUNIL 28

5.2 DESEMPENHO DO MODELO 1 28

5.3 LISTA ORDENADA INTEGRADA E EXEMPLOS DE CANDIDATOS 29

5.4 AVALIAÇÃO EXTERNA 29
5.5 CONTEXTUALIZAÇÃO BIBLIOGRÁFICA POSTERIOR À PRIORIZAÇÃO..... 30
6 DISCUSSÃO 32
7 CONSIDERAÇÕES FINAIS E CONTRIBUIÇÕES 33
REFERÊNCIAS 34
APÊNDICE A — ARQUITETURA 39

1 INTRODUÇÃO

O câncer de mama permanece entre as neoplasias de maior impacto sobre a saúde das mulheres. O rastreamento e o diagnóstico em tempo oportuno influenciam diretamente as possibilidades terapêuticas e o prognóstico, mas métodos computacionais baseados em biomarcadores moleculares ainda precisam demonstrar robustez, reprodutibilidade e generalização antes de qualquer aplicação clínica. Nesse contexto, a bioinformática pode contribuir para organizar evidências e reduzir o espaço de busca da pesquisa. Neste trabalho, uma hipótese significa um miRNA candidato que, por reunir sinais computacionais, merece ser investigado em novos estudos; não significa suspeita de doença em uma pessoa.

Os microRNAs são pequenas moléculas de RNA não codificante, geralmente com cerca de 22 nucleotídeos na forma madura, que regulam a expressão gênica em nível pós-transcricional. Alterações em seus níveis podem acompanhar processos relacionados à carcinogênese, e sua estabilidade em fluidos corporais favorece estudos de biópsia líquida (Mitchell *et al.*, 2008). Entretanto, resultados entre estudos variam conforme população, material biológico, plataforma, normalização e desenho experimental, exigindo cautela na transferência de assinaturas moleculares (Cardinali *et al.*, 2022).

Estudos com miRNAs circulantes demonstram potencial para detectar câncer de mama, mas também evidenciam heterogeneidade e risco de superestimação. Shimomura *et al.* (2016a), em estudo associado à série GEO GSE73002 (Shimomura *et al.*, 2016b), avaliaram milhares de amostras séricas e propuseram combinações de miRNAs para detecção precoce. Revisões e metanálises posteriores reforçam o potencial da área e, simultaneamente, apontam diferenças de protocolo, composição das coortes e validação como fontes de resultados divergentes (Garrido-Palacios *et al.*, 2023).

Diante disso, este trabalho desenvolve um fluxo computacional de descoberta e priorização de candidatos — isto é, um gerador de hipóteses baseado em ciência de dados. Sua pergunta prática é “quais miRNAs merecem ser investigados primeiro?”. O resultado central não é um laudo, uma previsão para um paciente nem uma ferramenta de pré-diagnóstico, mas uma lista ordenada de candidatos para orientar etapas posteriores de pesquisa. O Modelo 1 aprende padrões exclusivamente

de sequências maduras a partir de 43 marcadores positivos conhecidos e produz uma primeira lista ordenada com 2.613 miRNAs não rotulados. O Modelo 2 examina, para os 611 candidatos com dados disponíveis, se a expressão apresenta associação com as classes doente e saudável da base interna e produz uma segunda lista ordenada. A combinação dessas duas evidências gera a lista ordenada integrada de hipóteses, posteriormente avaliada, sem retreinamento, em uma coorte externa de soro.

O uso da sequência madura mantém o foco biológico nos miRNAs efetivamente funcionais. Foram avaliados k-mers, região-semente (*seed*, nucleotídeos 2 a 8 do miRNA maduro), comprimento, conteúdo GC, composição, entropia, posição e motivos terminais. Hairpin precursor, energia livre e estrutura secundária foram deliberadamente excluídos do fluxo computacional vigente para reduzir a complexidade e impedir que a pergunta do TCC se afastasse do miRNA maduro.

A hipótese metodológica avaliada é que padrões da sequência madura presentes em miRNAs já associados ao câncer de mama podem ajudar a priorizar outros candidatos relevantes e que parte desses candidatos também apresentará diferença de expressão entre as classes disponíveis. Se um candidato recebe apoio nas duas etapas, ele sobe na classificação e se torna uma hipótese mais prioritária para estudos independentes. Mesmo assim, ele não passa a ser um biomarcador confirmado: ainda são necessárias replicação em outras coortes, validação laboratorial e avaliação clínica. O desempenho do método é examinado por validação aninhada, comparação com ordenações aleatórias, análise interna *out-of-fold* (predições obtidas para cada amostra por modelos treinados sem ela) e teste externo congelado.

1.1 JUSTIFICATIVA

O câncer de mama apresenta elevada incidência e mortalidade no Brasil: o Instituto Nacional de Câncer estima 78.610 casos novos por ano no triênio 2026-2028 (Instituto Nacional de Câncer, 2026) e registrou 20.165 óbitos pela doença em 2023 (Instituto Nacional de Câncer, 2025). A pesquisa de biomarcadores pode contribuir para compreender mecanismos moleculares e orientar estudos futuros. Essa contribuição, contudo, deve ser separada de promessas de substituição da mamografia ou de aplicação assistencial imediata. Uma assinatura computacional somente pode ser considerada clinicamente útil depois de replicação independente,

validação laboratorial, calibração, análise de poder e avaliação em diagnósticos diferenciais.

A justificativa científica do projeto está na necessidade de reduzir o espaço de busca entre milhares de miRNAs maduros. Em vez de tratar todo miRNA fora da lista de referência como negativo, o Modelo 1 emprega aprendizado Positive-Unlabeled, apropriado quando existem positivos confiáveis e um universo não rotulado que pode conter novos positivos (Bekker; Davis, 2020). A separação por família de região-semente também reduz a possibilidade de que sequências muito aparentadas apareçam simultaneamente no treino e na validação.

A contribuição tecnológica consiste em um fluxo computacional reprodutível de ciência de dados que integra evidência de sequência madura, associação interna de expressão e avaliação externa congelada. O valor do trabalho está em reduzir milhares de possibilidades a listas ordenadas e transparentes de hipóteses auditáveis, acompanhadas de métricas, testes de sensibilidade e limitações. O projeto não realiza pré-diagnóstico e não deve ser apresentado como produto diagnóstico, dispositivo médico, substituto de exames ou modelo pronto para uso em pacientes.

1.2 OBJETIVOS

1.2.1 Objetivo geral

Desenvolver e avaliar um fluxo computacional reprodutível que integre padrões da sequência madura e evidências de expressão, a fim de reduzir, de forma auditável, o espaço de busca entre milhares de miRNAs, priorizar candidatos potencialmente associados ao câncer de mama para estudos posteriores e verificar a robustez dos sinais em uma coorte externa, sem atribuir finalidade diagnóstica ao resultado.

1.2.2 Objetivos específicos

a) realizar revisão bibliográfica e curadoria de miRNAs maduros associados ao câncer de mama, registrando fontes, nomes resolvidos e pesos de treinamento, para construir um conjunto positivo rastreável, evitar inconsistências de nomenclatura e explicitar a contribuição de cada evidência para o treinamento;

b) representar as sequências maduras por k-mers, região-semente, composição e atributos posicionais, excluindo hairpin e estrutura secundária do escopo ativo, para concentrar a análise na forma funcional do miRNA e limitar a complexidade a atributos diretamente relacionados à pergunta de pesquisa;
c) treinar o Modelo 1 com aprendizado Positive-Unlabeled por bagging, pontuação out-of-bag e validação aninhada por família de região-semente, para ranquear miRNAs ainda não rotulados sem tratá-los como negativos confirmados e reduzir o risco de vazamento de informação entre sequências aparentadas;
d) avaliar, no Modelo 2, por validação cruzada out-of-fold, tamanhos de efeito, intervalos de confiança e FDR, a associação interna entre a expressão dos candidatos disponíveis e as classes observadas, para identificar apoio adicional aos candidatos do Modelo 1 e quantificar sua incerteza sem apresentar essa triagem como validação biológica independente;
e) integrar os escores dos dois modelos, testar a sensibilidade a diferentes pesos e congelar candidatos, direções e critérios antes da avaliação externa, para priorizar hipóteses apoiadas por evidências complementares e verificar a estabilidade da ordenação;
f) testar a lista ordenada congelada na coorte externa GSE73002, quantificando cobertura, concordância direcional, AUC, FDR, deslocamento global e robustez entre análises, para verificar se os sinais reaparecem fora da base interna e delimitar quais candidatos merecem novas avaliações independentes.

2 REVISÃO BIBLIOGRÁFICA

A revisão bibliográfica concentra-se em miRNAs, câncer de mama, biomarcadores circulantes e métodos computacionais de priorização. A forma madura do miRNA é a unidade funcional utilizada neste projeto; embora o precursor hairpin participe da biogênese, ele não integra as features do fluxo computacional. As sequências humanas maduras foram obtidas do miRBase, base de referência para nomenclatura e sequências de miRNAs (Kozomara; Birgaoanu; Griffiths-Jones, 2019).

A literatura relata miRNAs circulantes potencialmente associados a diagnóstico, prognóstico e características tumorais. Contudo, painéis diferentes nem sempre se reproduzem entre soro, plasma e tecido, e diferenças de plataforma ou normalização podem gerar deslocamentos sistemáticos. Por isso, significância estatística em uma única base não basta: direção, magnitude, incerteza, correção para múltiplos testes e avaliação externa precisam ser examinadas conjuntamente.

No componente computacional, o problema é mais próximo de descoberta do que de classificação supervisionada convencional: existem positivos descritos na literatura, mas os demais miRNAs não podem ser assumidos como negativos. O aprendizado Positive-Unlabeled oferece um enquadramento mais adequado (Elkan; Noto, 2008; Mordelet; Vert, 2014), enquanto a separação por família de região-semente, a pontuação out-of-bag e o congelamento anterior ao teste externo reduzem formas específicas de vazamento e ajuste pós-resultado.

Na literatura computacional, a predição de associações entre miRNAs e doenças é um problema estabelecido, abordado por modelos baseados em medidas de similaridade, em redes e em aprendizado de máquina, em geral apoiados em bases curadas de associações com suporte experimental, como o HMDD (Chen *et al.*, 2019; Huang *et al.*, 2019). O presente trabalho difere dessas abordagens ao restringir o Modelo 1 à sequência madura e ao submeter a lista ordenada a uma coorte externa congelada. Bases como o HMDD também podem servir, em trabalhos futuros, como verificação bibliográfica independente dos candidatos priorizados.

2.1 TRABALHOS RELACIONADOS

Esta seção apresenta trabalhos que fundamentam o uso de miRNAs circulantes e, ao mesmo tempo, demonstram por que a validação externa e o controle de

limitações são necessários. A comparação com a literatura orientou a curadoria dos positivos, mas a recorrência bibliográfica não participa diretamente do escore integrado vigente.

Shimomura *et al.* (2016a) investigaram combinações de miRNAs séricos para detecção de câncer de mama em grande número de amostras e disponibilizaram os dados associados à série GSE73002 (Shimomura *et al.*, 2016b). O estudo fornece a base externa utilizada neste TCC. Cinco dos 43 positivos curados pelo projeto (miR-1246, miR-1307-3p, miR-4634, miR-6861-5p e miR-6875-5p) também vieram dessa publicação, cujo painel foi validado pelos autores justamente na coorte de teste aqui utilizada, criando dependência bibliográfica indireta que foi mantida explicitamente como limitação.

Garrido-Palacios *et al.* (2023) realizaram revisão sistemática e metanálise sobre desregulação de miRNAs no diagnóstico precoce do câncer de mama. O trabalho reforça o potencial dos miRNAs e evidencia heterogeneidade entre estudos, incluindo diferenças de amostra, plataforma e composição dos painéis. Esses fatores justificam evitar a interpretação de uma única coorte como confirmação definitiva.

Cardinali *et al.* (2022) revisaram o uso de miRNAs circulantes no diagnóstico e prognóstico do câncer de mama. A estabilidade dessas moléculas em fluidos corporais favorece a investigação minimamente invasiva, porém etapas pré-analíticas e analíticas podem alterar os níveis medidos. No presente projeto, essa observação fundamenta a distinção entre sinal biológico e deslocamento técnico de coorte.

Adam-Artigues *et al.* (2021) propuseram uma assinatura plasmática de dois miRNAs voltada à detecção muito precoce. O estudo ilustra o valor de painéis compactos, mas também mostra que resultados dependem do contexto experimental e do material biológico. Assim, achados em plasma, soro e tecido não devem ser tratados como diretamente intercambiáveis.

Kim *et al.* (2024) analisaram assinaturas de miRNAs em vesículas extracelulares derivadas de tumores como complemento à mamografia, mostrando que o compartimento biológico de medição influencia a informação capturada. Essa diversidade de abordagens reforça que uma ferramenta exploratória deve preservar a rastreabilidade da origem dos dados e declarar incompatibilidades de material e tecnologia.

Outros estudos avaliaram miRNAs circulantes, isolados ou combinados em painéis, como candidatos a biomarcadores do câncer de mama em soro, plasma e exossomos plasmáticos (Chen *et al.*, 2013; Guo *et al.*, 2020; Hannafon *et al.*, 2016; Heneghan *et al.*, 2010; Jang *et al.*, 2021; Ng *et al.*, 2013; Shen *et al.*, 2014; Si *et al.*, 2013; Wang *et al.*, 2023). As fontes de cada um dos 43 marcadores positivos usados no treinamento estão no Quadro 1.

Em síntese, a literatura sustenta o potencial dos miRNAs, mas não elimina riscos de heterogeneidade, lote, seleção de variáveis e sobreajuste. A contribuição deste projeto é combinar aprendizado de padrões maduros, triagem interna e avaliação externa congelada em um fluxo auditável. O objetivo não é superar estudos clínicos existentes, e sim produzir uma lista priorizada e cientificamente qualificável para investigações posteriores.

2.2 TIPO E OBJETO DE PESQUISA

Quanto à natureza, trata-se de pesquisa aplicada, quantitativa, exploratória e computacional, conduzida retrospectivamente com dados secundários. O estudo desenvolve e avalia métodos de priorização de hipóteses, sem intervenção em participantes, coleta prospectiva ou validação clínica. A reprodutibilidade é apoiada por scripts, artefatos versionados, hashes e auditorias automatizadas.

Por utilizar exclusivamente dados secundários desidentificados, obtidos de repositórios públicos e sem possibilidade de identificação individual, a pesquisa enquadra-se nas hipóteses de dispensa de registro e avaliação pelo sistema CEP/Conep previstas no art. 1º, parágrafo único, da Resolução CNS nº 510/2016 (Brasil, 2016).

De forma complementar, o trabalho incorpora pesquisa bibliográfica para curar os marcadores positivos, contextualizar a biologia dos miRNAs e interpretar os candidatos. A literatura não é utilizada como um terceiro escore na classificação atual; seu papel é definir referências de treinamento, apoiar a discussão e evitar afirmações incompatíveis com o estado da evidência.

O objeto de pesquisa é um fluxo computacional com duas etapas de modelagem: o Modelo 1 aprende padrões da sequência madura e ranqueia miRNAs não rotulados; o Modelo 2 acrescenta associação interna de expressão aos

candidatos disponíveis. A lista ordenada integrada é avaliada posteriormente em uma coorte externa distinta, sem retreinamento.

2.3 POPULAÇÃO OU AMOSTRA DE ESTUDO

A população de interesse é formada por pessoas com câncer de mama e controles sem câncer representados em bases moleculares secundárias. A base interna contém 2.678 registros balanceados: 1.339 amostras de classe 1 provenientes de arquivos de quantificação de miRNA com nomes no padrão do fluxo de processamento harmonizado do GDC (1.209 com sufixo mirbase21 e 130 com sufixo mirnaseq), expressas em leituras por milhão (RPM) no nível do precursor (miRBase 21); e 1.339 controles de classe 0 extraídos da matriz de miRNAs em TPM do portal GTEx (GTEx Consortium, 2020), provenientes de 82 doadores e de múltiplos tecidos, quantificados no nível do miRNA maduro e agregados por nome-base para as colunas de precursor. O repositório não possui manifesto clínico que comprove, amostra por amostra, a procedência dos UUIDs da classe 1. Como os controles incluem várias amostras do mesmo doador, as observações não são independentes, e as duas fontes usam unidades e níveis de anotação diferentes.

Na base interna, classe e fonte variam juntas: todos os controles são GTEx e todos os registros da classe doente vêm do outro arquivo. Portanto, o Modelo 2 não consegue separar completamente doença de origem, processamento ou lote. As 371 features comuns evitam colunas exclusivas de uma fonte, mas não removem esse confundimento estrutural; por isso, as métricas internas são descritas como associação e triagem.

A avaliação externa utilizou a divisão de teste da GSE73002 (Shimomura *et al.*, 2016a, 2016b): 1.206 amostras de soro de pessoas com câncer de mama e 1.343 controles sem câncer, medidas na mesma plataforma (3D-Gene, Toray, com sondas baseadas na release 20 do miRBase), com 2.540 miRNAs medidos. Não houve coincidência literal entre os IDs GSM externos e os IDs internos, mas, como os sistemas de identificação diferem, isso não prova sozinho independência no nível da pessoa.

2.3.1 Critérios de inclusão

Foram incluídos no estudo os dados que atenderam aos seguintes critérios:

a) miRNAs positivos com evidência bibliográfica, nome maduro resolvido e sequência humana disponível no miRBase;
b) sequências maduras compostas pelo alfabeto de RNA e adequadas à extração de k-mers, região-semente e atributos posicionais;
c) registros internos com identificador único, classe binária válida e valores numéricos finitos de expressão;
d) features de expressão mapeadas de forma comum entre as duas fontes internas, totalizando 371 colunas;
e) candidatos não positivos pontuados apenas por modelos out-of-bag e, no Modelo 2, com expressão disponível;
f) amostras externas dos grupos predefinidos TS_B e TS_N, com escala log2 declarada e rastreabilidade por acesso GSM;
g) correspondências maduras exatas como desfecho externo primário, mantendo proxies de família em categoria secundária separada.

2.3.2 Critérios de exclusão

Foram excluídos ou tratados fora do desfecho primário os seguintes dados:

a) sequências ausentes, inválidas ou não humanas no universo maduro utilizado;
b) os 43 positivos conhecidos do conjunto de candidatos não rotulados, evitando ranqueá-los como novas descobertas;
c) candidatos sem expressão na base interna, que permanecem na lista ordenada do Modelo 1, mas não entram no Modelo 2;
d) amostras com IDs duplicados, classes inválidas, células vazias ou valores incompatíveis com a escala declarada;
e) proxies de família ou precursor do total primário de replicações maduras exatas;
f) hairpin precursor, estrutura secundária e energia livre mínima, por decisão explícita de escopo;

g) a divisão TR da GSE73002 e os grupos ausentes do ZIP; as 54 amostras oficiais de doença mamária benigna não foram avaliadas nesta versão.

3 DESCRIÇÃO DO PROCESSO DE COLETA DE DADOS

A coleta computacional reuniu três tipos de insumo: sequências maduras e marcadores positivos para o Modelo 1, expressão interna para o Modelo 2 e uma coorte de soro para avaliação externa. Nenhuma coleta direta foi realizada com participantes. Todos os dados analisados são secundários, e os artefatos necessários à reprodução estão organizados no repositório.

3.1 FONTES E SELEÇÃO DOS DADOS

A base interna foi construída a partir de um CSV de amostras da classe doente e de uma matriz GTEx de controles. Os formatos originais eram diferentes: a matriz saudável apresentava amostras em colunas e identificadores RNAcentral em linhas. O mapeamento RNAcentral/miRBase e a transposição produziram 2.678 amostras e 371 features comuns. A origem da classe 1 é descrita de forma conservadora porque o manifesto clínico correspondente não está versionado.

Para o Modelo 1, foi utilizado o arquivo local mirbase_mature.fa do miRBase (Kozomara; Birgaoanu; Griffiths-Jones, 2019), com 2.656 sequências humanas maduras únicas, e uma lista curada de 43 positivos distribuídos em 32 famílias de região-semente (Quadro 1). Como o arquivo local não preserva metadados suficientes para distinguir com segurança as releases 22 e 22.1, a versão exata não é afirmada. O FASTA de hairpins e os atributos estruturais não integram a versão final do fluxo computacional. Os 2.613 miRNAs restantes foram tratados como não rotulados, e não como negativos biológicos confirmados.

Dos 43 positivos, 33 têm ao menos uma publicação de origem e 10 vêm do painel inicial do projeto, ainda sem fonte bibliográfica registrada. Cada positivo recebeu peso 3 (recorrência bibliográfica alta), 2 (recorrência média ou painel inicial) ou 1 (candidato exploratório), redistribuído entre os membros da mesma família de região-semente para preservar o peso total.

Quadro 1 — Marcadores positivos usados no treinamento do Modelo 1

miRNA maduro	Direção relatada	Material	Fonte(s)	Peso
miR-10b-5p	Não informada	soro	Ali *et al.* (2022); Mar-Aguilar *et al.* (2013); Miranda *et al.* (2024); Turkoglu, Calisir e Ozturk (2024)	3

miRNA maduro	Direção relatada	Material	Fonte(s)	Peso
miR-125b-5p	Não informada	soro	Han *et al.* (2017); Mar-Aguilar *et al.* (2013); Turkoglu, Calisir e Ozturk (2024)	3
miR-145-5p	Não informada	soro	Han *et al.* (2017); Mar-Aguilar *et al.* (2013); Turkoglu, Calisir e Ozturk (2024); Zhu *et al.* (2009)	3
miR-155-5p	Não informada	soro	Han *et al.* (2017); Mar-Aguilar *et al.* (2013); Sochor *et al.* (2014); Sun *et al.* (2012); Turkoglu, Calisir e Ozturk (2024); Wang *et al.* (2014); Zhu *et al.* (2009)	3
miR-195-5p	Não informada	soro	Miranda *et al.* (2024); Turkoglu, Calisir e Ozturk (2024); Liu *et al.* (2019)	3
miR-21-5p	Não informada	soro	Ali *et al.* (2022); Gao *et al.* (2013); Han *et al.* (2017); Mar-Aguilar *et al.* (2013); Miranda *et al.* (2024); Toraih *et al.* (2015); Turkoglu, Calisir e Ozturk (2024)	3
miR-210-3p	Não informada	soro	Miranda *et al.* (2024); Turkoglu, Calisir e Ozturk (2024)	2
miR-34a-5p	Não informada	soro	Miranda *et al.* (2024); Turkoglu, Calisir e Ozturk (2024)	2
let-7b-5p	Redução	soro, exossomo, tecido	painel inicial do projeto (sem fonte registrada)	2
miR-106a-5p	Aumento	soro, exossomo, tecido	painel inicial do projeto (sem fonte registrada)	2
miR-16-5p	Aumento	soro, exossomo, tecido	Miranda *et al.* (2024); Zhu *et al.* (2009); painel inicial do projeto (sem fonte registrada)	2
miR-19a-3p	Aumento	soro, exossomo, tecido	Sochor *et al.* (2014); painel inicial do projeto (sem fonte registrada)	2
miR-19b-3p	Aumento	soro, exossomo, tecido	painel inicial do projeto (sem fonte registrada)	2
miR-20a-5p	Variável	soro, exossomo, tecido	painel inicial do projeto (sem fonte registrada)	2
miR-223-3p	Variável	soro, exossomo, tecido	painel inicial do projeto (sem fonte registrada)	2
miR-25-3p	Aumento	soro, exossomo, tecido	painel inicial do projeto (sem fonte registrada)	2
miR-425-5p	Aumento	soro, exossomo, tecido	painel inicial do projeto (sem fonte registrada)	2
miR-451a	Aumento	soro, exossomo, tecido	painel inicial do projeto (sem fonte registrada)	2
miR-92a-3p	Aumento	soro, exossomo, tecido	painel inicial do projeto (sem fonte registrada)	2

miRNA maduro	Direção relatada	Material	Fonte(s)	Peso
miR-93-5p	Aumento	soro, exossomo, tecido	painel inicial do projeto (sem fonte registrada)	2
let-7a-5p	Não informada	soro	Turkoglu, Calisir e Ozturk (2024)	1
miR-1-3p	Não informada	soro	Miranda *et al.* (2024)	1
miR-1246	Não informada	soro	Shimomura *et al.* (2016a)	1
miR-125a-5p	Não informada	soro	Turkoglu, Calisir e Ozturk (2024)	1
miR-1307-3p	Não informada	soro	Shimomura *et al.* (2016a)	1
miR-139-5p	Não informada	soro	Turkoglu, Calisir e Ozturk (2024)	1
miR-17-5p	Não informada	soro	Turkoglu, Calisir e Ozturk (2024)	1
miR-181b-5p	Não informada	soro	Sochor *et al.* (2014)	1
miR-191-5p	Não informada	soro	Mar-Aguilar *et al.* (2013)	1
miR-200a-3p	Não informada	soro	Turkoglu, Calisir e Ozturk (2024)	1
miR-205-5p	Não informada	soro	Turkoglu, Calisir e Ozturk (2024)	1
miR-206	Não informada	soro	Turkoglu, Calisir e Ozturk (2024)	1
miR-24-3p	Não informada	soro	Sochor *et al.* (2014)	1
miR-31-5p	Não informada	soro	Turkoglu, Calisir e Ozturk (2024)	1
miR-365a-3p	Não informada	soro	Han *et al.* (2017)	1
miR-373-3p	Não informada	soro	Turkoglu, Calisir e Ozturk (2024)	1
miR-382-5p	Não informada	soro	Mar-Aguilar *et al.* (2013)	1
miR-4634	Não informada	soro	Shimomura *et al.* (2016a)	1
miR-497-5p	Não informada	soro	Turkoglu, Calisir e Ozturk (2024)	1
miR-520c-3p	Não informada	soro	Turkoglu, Calisir e Ozturk (2024)	1
miR-6861-5p	Não informada	soro	Shimomura *et al.* (2016a)	1
miR-6875-5p	Não informada	soro	Shimomura *et al.* (2016a)	1
miR-99a-5p	Não informada	soro	Turkoglu, Calisir e Ozturk (2024)	1

Fonte: Os autores (2026), com base nas referências indicadas.

A coorte externa corresponde à série GSE73002 do NCBI GEO (Shimomura *et al.*, 2016b) e foi utilizada a partir de um arquivo ZIP com uma matriz de 3.966 amostras por 2.540 miRNAs e um mapa de rastreabilidade. O contraste predefinido selecionou somente TS_B e TS_N, totalizando 2.549 amostras. A matriz preparada preservou os acessos GSM e a escala log2 normalizada por quantis, sem aplicação de um segundo logaritmo.

3.2 INTEGRIDADE E RASTREABILIDADE DOS DADOS

Antes do cálculo externo, foram congelados os modelos, a lista ordenada, as direções esperadas, os critérios e os hashes dos artefatos. O protocolo anterior aos resultados foi registrado na tag pre-resultados-gse73002-v1. Essa separação reduz o risco de modificar candidatos ou limiares em resposta ao desempenho observado na coorte.

A revisão computacional verificou a integridade dos dados, a correspondência dos 43 positivos com o FASTA maduro, a separação das famílias de região-semente entre treino e validação e a pontuação out-of-bag dos candidatos. Na coorte externa, foram conferidos os identificadores, as classes, a escala e a correspondência com a matriz oficial. O fluxo computacional possui 141 verificações automatizadas e 15 testes unitários estatísticos. Esses controles demonstram consistência e determinismo computacional, mas não substituem validação biológica, laboratorial ou clínica.

4 DESCRIÇÃO DO PROCESSO DE ANÁLISE DE DADOS

4.1 VISÃO GERAL DO FUNIL

A análise foi organizada como um funil de geração de hipóteses. Os 43 miRNAs positivos conhecidos servem como referências para o Modelo 1. Esse modelo aprende padrões de sequência madura e gera uma primeira lista ordenada com 2.613 candidatos. Entre eles, 611 possuem correspondência na base interna de expressão e seguem para o Modelo 2. O segundo modelo não confirma biomarcadores: ele verifica associação interna entre a expressão e os rótulos disponíveis, atribuindo evidência adicional aos candidatos avaliáveis. A combinação dos dois escores forma a lista ordenada integrada. Somente depois de congelada, essa lista é levada à coorte externa GSE73002. A arquitetura do fluxo computacional e o fluxo de treinamento e avaliação estão representados nas Figuras 1 e 2 (Apêndice A).

Os 2.002 candidatos sem expressão interna não são descartados biologicamente. Eles permanecem na lista ordenada do Modelo 1 e são classificados como não avaliáveis na segunda etapa com os dados atuais. Da mesma forma, um candidato mal posicionado no Modelo 2 não é declarado irrelevante: sua evidência de expressão é apenas menos favorável ou inconclusiva nesta montagem.

4.2 MODELO 1 — PRIORIZAÇÃO PELA SEQUÊNCIA MADURA

Cada sequência madura é representada por k-mers globais e posicionais, região-semente, comprimento, conteúdo GC, composição de nucleotídeos, entropia e motivos terminais. Hairpin precursor, energia livre e estrutura secundária não participam do fluxo computacional vigente. Como existem positivos confiáveis, mas não há um conjunto confiável de negativos, foi adotado aprendizado Positive-Unlabeled por bagging (Elkan; Noto, 2008; Mordelet; Vert, 2014).

O ensemble final contém 20 bags. Em cada um, todos os positivos são combinados com 800 miRNAs não rotulados usados apenas como contraste temporário. Cada candidato é pontuado somente pelos modelos em que não foi usado como contraste. A validação é aninhada (Varma; Simon, 2006) e separada por família de região-semente, reduzindo o risco de avaliar uma sequência com parentes muito

próximos vistos no treinamento. O resultado é uma prioridade relativa de semelhança com os padrões aprendidos, não uma probabilidade de câncer.

4.3 MODELO 2 — TRIAGEM INTERNA DE ASSOCIAÇÃO DE EXPRESSÃO

O Modelo 2 recebe os 611 candidatos com features de expressão disponíveis. Para cada candidato, uma regressão logística univariada é ajustada e avaliada por predições out-of-fold em cinco folds. Seu escore combina 70% de AUC orientada pela direção, 20% da magnitude absoluta do log2FC (*log2 fold change*, logaritmo na base 2 da razão entre as médias dos grupos) e 10% da diferença de detecção. Esse procedimento cria uma lista ordenada por associação interna; não valida biologicamente o miRNA e não mede desempenho de um teste clínico.

A principal limitação dessa etapa é o confundimento estrutural entre classe e fonte: todos os controles são GTEx e todos os registros rotulados como doentes vêm de outro arquivo de quantificação. Além disso, há diferenças de unidade e nível de agregação, e as amostras GTEx incluem tecidos repetidos de um número menor de doadores. Assim, as métricas podem refletir doença, tecido, lote, processamento, doador ou uma combinação desses fatores (Leek *et al.*, 2010). Por essa razão, a etapa é denominada triagem interna, e não validação em pacientes.

As 611 linhas correspondem a 325 hipóteses de expressão únicas porque várias features estão em nível de precursor ou família. Em 552 candidatos, a base interna não distingue completamente os braços maduros 5p e 3p. Essa ambiguidade é registrada e impede atribuir a evidência interna exclusivamente a um dos braços.

4.4 INTEGRAÇÃO E AVALIAÇÃO EXTERNA

A lista ordenada integrada combina 50% do percentil do Modelo 1 e 50% do escore do Modelo 2. Também foram calculados cenários 75/25 e 25/75 para verificar a dependência da ponderação (Seção 5.3). O escore final serve apenas para ordenar hipóteses: não representa risco individual, probabilidade de doença, confiança clínica ou chance de confirmação laboratorial.

A lista ordenada, as direções esperadas, os critérios e os hashes foram congelados antes da avaliação externa. A GSE73002 contém, no contraste principal, 1.206 amostras de soro de pessoas com câncer de mama e 1.343 controles sem

câncer. A coorte não altera os escores nem retreina os modelos; ela verifica se os sinais aparecem novamente. Correspondências maduras exatas constituem a análise principal, enquanto proxies de família são apresentados separadamente.

Uma auditoria revelou forte deslocamento global na GSE73002. Por isso, além da análise principal na escala log2 original, foi realizada uma sensibilidade pós-hoc que subtrai a média de cada amostra. A interseção entre as duas análises é mais conservadora do que qualquer uma delas isoladamente.

4.5 INTERPRETAÇÃO DAS MÉTRICAS

No Modelo 1, o percentil médio informa a posição relativa das famílias positivas ocultas em relação ao fundo não rotulado. Recall@10% e Recall@20% indicam quantas famílias ocultas aparecem, respectivamente, nos primeiros 10% e 20% da lista ordenada. Intervalos bootstrap e ordenações aleatórias de Monte Carlo quantificam incerteza e desempenho esperado ao acaso.

No Modelo 2 e na coorte externa, AUC, log2FC, diferença média, Cliff's delta e Hedges g descrevem separação, direção e magnitude. Os valores-p são corrigidos pelo procedimento de Benjamini-Hochberg (Benjamini; Hochberg, 1995). Essas medidas ajudam a comparar hipóteses, mas seus valores não devem ser traduzidos como capacidade de diagnosticar uma pessoa.

Na avaliação externa, um sinal é marcado como reproduzido quando possui ao menos 10 amostras por classe, direção concordante, limite inferior do IC95% da AUC direcional (Hanley; McNeil, 1982) acima de 0,5 e FDR menor que 0,05. AUC de pelo menos 0,60 é usada apenas como descrição de magnitude, não como limiar clínico.

4.6 ALGORITMOS, FERRAMENTAS E BIBLIOTECAS

O projeto foi implementado em Node.js e PowerShell. O núcleo analítico gera modelos JSON, listas ordenadas em CSV, relatórios textuais, resumos de auditoria e um dashboard HTML. Os principais scripts são train_mirna_candidate_discovery_model.js, validate_mirna_candidates_in_patients_model.js e validate_mirna_external_cohort.js. Apesar do nome histórico do segundo arquivo, sua função vigente é triagem interna de associação, não predição clínica.

As saídas congeladas possuem hashes registrados. Os classificadores históricos permanecem apenas para rastreabilidade e não integram os resultados deste TCC.

5 RESULTADOS

5.1 RESULTADO GERAL DO FUNIL

O principal resultado não é uma classificação de pessoas, mas a redução organizada do espaço de busca. A Tabela 1 apresenta o que entra e o que sai de cada etapa, evitando interpretar as contagens como resultados independentes.

Tabela 1 — Síntese do funil de geração de hipóteses

Etapa	Saída	Interpretação correta
Referências positivas	43 miRNAs em 32 famílias	Base de aprendizado; não são novos candidatos
Modelo 1	2.613 candidatos ranqueados	Prioridade por padrões da sequência madura
Disponibilidade interna	611 avaliáveis; 2.002 não avaliáveis	Ausência de expressão não significa descarte biológico
Lista ordenada integrada	611 hipóteses reordenadas	Combinação 50/50 entre sequência e associação interna
Coorte externa	579 exatos; 23 proxies; 9 ausentes	Teste congelado, sem retreinamento
Conjunto convergente	211 sinais nas duas análises	Evidência externa mais conservadora
Núcleo maduro estrito	22 candidatos	Convergentes e sem ambiguidade interna de braço

Fonte: Os autores (2026), a partir dos artefatos do fluxo computacional.

5.2 DESEMPENHO DO MODELO 1

O Modelo 1 apresentou percentil médio por família de 64,60%, acima do esperado em ordenações aleatórias (Tabela 2). Entretanto, o Recall@10% não foi significativo e o resultado ficou próximo ao de uma linha de base construída apenas com a composição da sequência madura. Portanto, o modelo captou um sinal global, mas ainda não demonstrou forte concentração das famílias positivas no topo mais restrito.

Tabela 2 — Resultados essenciais do Modelo 1

Medida	Resultado	Leitura
Percentil médio por família	64,60%	Sinal global acima do acaso; IC95% de 55,85% a 72,85%
Recall@10%	4/32 (12,50%)	Não significativo; p = 0,2417
Recall@20%	13/32 (40,63%)	Resultado exploratório favorável
Linha de base de composição	63,54%	Desempenho próximo ao Modelo 1
Síntese	Sinal global modesto	Útil para priorização exploratória, não para confirmação

Fonte: Os autores (2026). Resultados por família de região-semente nos folds externos.

5.3 LISTA ORDENADA INTEGRADA E EXEMPLOS DE CANDIDATOS

Os cinco primeiros colocados foram miR-32-3p, let-7f-5p, miR-32-5p, miR-95-5p e miR-200b-3p (Tabela 3). A posição alta não garante reprodução: o miR-95-5p, quarto colocado, não confirmou a direção esperada em nenhuma das duas análises externas. Em contraste, o miR-106a-3p, 19º colocado, reproduziu nas duas análises e pertence ao núcleo estrito de 22 candidatos. Esses exemplos mostram por que a lista ordenada deve ser lida como ordem de investigação, e não como lista de biomarcadores confirmados.

Tabela 3 — Candidatos selecionados para interpretação

Posição	Candidato	Reproduziu nas duas análises	Núcleo estrito	Leitura
1	miR-32-3p	sim	não	Top 1; evidência interna compartilhada entre braços
2	let-7f-5p	sim	não	Top 2; evidência interna compartilhada entre braços
3	miR-32-5p	sim	não	Mesmo precursor de miR-32-3p na base interna
4	miR-95-5p	não	não	Exemplo de posição alta sem reprodução externa
5	miR-200b-3p	sim	não	Reprodução externa com ambiguidade interna
13	miR-182-5p	sim	não	Reprodução externa e literatura em tecido triplo-negativo
19	miR-106a-3p	sim	sim	Reprodução externa, braço específico e literatura em plasma

Fonte: Os autores (2026). A seleção é ilustrativa e não substitui a lista ordenada completa disponibilizada em CSV.

Os cenários alternativos de ponderação indicaram estabilidade global, mas sensibilidade relevante no topo. Com 75% do peso no Modelo 1, 8 dos 10 primeiros candidatos da combinação 50/50 permaneceram entre os 10 primeiros; com 75% do peso no Modelo 2, apenas 5 permaneceram. A correlação de Spearman com a lista ordenada 50/50 foi de 0,872 e 0,906, respectivamente.

5.4 AVALIAÇÃO EXTERNA

Entre os 611 candidatos congelados, 579 tiveram correspondência madura exata, 23 foram mapeados apenas por proxy e 9 estavam ausentes. Na análise principal, 255 dos 579 candidatos com correspondência madura exata foram reproduzidos, estabelecendo uma taxa global de 44,0%. Embora 7 dos 10 primeiros

tenham reproduzido, a concordância foi fortemente assimétrica: ocorreu em 245 dos 248 candidatos cuja direção esperada era de aumento e em apenas 10 dos 331 cuja direção esperada era de redução. Nos cortes do topo, a reprodução seguiu exatamente essa direção: reproduziram todos os candidatos de aumento esperado e nenhum de redução esperada, tanto entre os 10 primeiros (7 de 10) quanto entre os 50 primeiros (34 de 47 avaliáveis) e os 100 primeiros (60 de 96). Esse padrão é compatível com o deslocamento global da coorte e limita a atribuição da reprodução exclusivamente à qualidade da lista ordenada.

Esses números precisam ser interpretados junto com o deslocamento global: 95,67% das features apresentaram média maior no grupo câncer, e a média por amostra separou as classes com AUC de 0,971. Após centralizar cada amostra, 271 sinais exatos atenderam ao critério; 211 coincidiram com a análise principal e 203 mantiveram AUC de pelo menos 0,60 nas duas análises. O núcleo mais rigoroso contém 22 candidatos sem ambiguidade interna de braço, dos quais 21 mantiveram essa magnitude.

A correlação de Spearman entre o escore integrado interno e a AUC externa foi baixa (rho = 0,0852) e ficou praticamente nula na análise centrada. Assim, a coorte apoia a recorrência de parte dos sinais, mas não confirma a ordem completa da lista. A matriz local também não contém as 54 amostras oficiais de doença mamária benigna; a especificidade contra diagnósticos diferenciais não foi testada.

5.5 CONTEXTUALIZAÇÃO BIBLIOGRÁFICA POSTERIOR À PRIORIZAÇÃO

A literatura foi consultada depois da construção da lista ordenada e não acrescenta pontos aos candidatos. O miR-106a-3p é o exemplo mais sólido para apresentação: ocupa a 19ª posição, pertence ao núcleo estrito e já foi descrito com níveis plasmáticos aumentados em um estudo com 200 pacientes e 200 controles (Li *et al.*, 2018). O miR-182-5p, 13º colocado, apresentou expressão diferencial em tecido de câncer de mama triplo-negativo em uma coorte de mulheres latinas (Almohaywi *et al.*, 2023). Nesse estudo, porém, o aumento no tumor apareceu na comparação não pareada com o tecido adjacente, enquanto, na análise pareada, os autores relataram apenas reduções entre os pares com diferença; a citação apoia, portanto, a existência de desregulação, mas não uma direção consistente.

O miR-32-3p, primeiro colocado, integrou uma assinatura de cinco miRNAs circulantes estudada por Vishnubalaji *et al.* (2026). Entretanto, esse apoio é apenas parcialmente independente, pois o estudo também utilizou a GSE73002 em sua validação externa. A recorrência bibliográfica aumenta a plausibilidade de investigação, mas não comprova causalidade, especificidade ou utilidade clínica.

6 DISCUSSÃO

Os resultados sustentam parcialmente a hipótese de pesquisa. O Modelo 1 recuperou famílias ocultas acima do acaso, porém seu ganho em relação a uma linha de base simples foi pequeno e o enriquecimento no primeiro décimo não foi significativo. O Modelo 2 acrescentou uma dimensão de expressão, mas sua base não permite separar doença de origem e processamento. A avaliação externa fortaleceu um subconjunto de hipóteses, ao mesmo tempo em que revelou deslocamento global e baixa correspondência entre a ordem interna e o desempenho externo.

A principal contribuição do trabalho é metodológica: transformar um universo de milhares de miRNAs em uma lista rastreável, com níveis explícitos de evidência e limitações. Os 211 sinais convergentes não devem ser apresentados como 211 biomarcadores. Eles constituem candidatos que sobreviveram a duas leituras da mesma coorte externa. Os 22 candidatos estritos são um subconjunto mais conservador, mas também permanecem hipóteses.

A pesquisa bibliográfica posterior à priorização ajuda a selecionar casos para discussão e planejamento experimental. Candidatos com apoio independente, reprodução externa e ausência de ambiguidade de braço, como miR-106a-3p, oferecem pontos de partida mais claros. Candidatos pouco estudados podem representar novidade, mas exigem maior cautela e confirmação independente.

As limitações centrais são: apenas 43 positivos e 32 famílias de região-semente; proximidade do Modelo 1 com a linha de base de composição; confundimento da base interna; repetição de doadores GTEx; agregação de expressão em nível de precursor; forte deslocamento global na GSE73002; ausência do grupo de doença mamária benigna no ZIP; dependência bibliográfica indireta de cinco positivos; e inexistência de uma segunda coorte externa completamente independente.

7 CONSIDERAÇÕES FINAIS E CONTRIBUIÇÕES

O produto deste TCC é um gerador computacional de hipóteses científicas. Ele aprende padrões de sequências maduras, acrescenta evidência exploratória de expressão, organiza candidatos em uma lista ordenada e verifica sua recorrência em uma coorte externa. Ele não realiza diagnóstico ou pré-diagnóstico, não recebe dados de uma pessoa para emitir uma decisão, não estima risco individual, não substitui exames e não está calibrado ou validado para uso clínico.

Dos 2.613 candidatos priorizados pelo Modelo 1, 611 possuíam dados de expressão disponíveis e seguiram para a triagem interna do Modelo 2. Na avaliação externa, 211 sinais foram concordantes nas análises principal e centrada, e 22 formaram um núcleo maduro mais conservador. Esses números representam graus de priorização computacional, não estágios de comprovação de biomarcadores.

As contribuições incluem o uso de aprendizado Positive-Unlabeled, validação separada por família de região-semente, pontuação out-of-bag, integração transparente entre sequência e expressão, congelamento anterior ao teste externo, auditoria do deslocamento global e distinção explícita entre candidatos gerais, sinais convergentes e núcleo sem ambiguidade de braço.

Como próximos passos, recomenda-se confirmar a procedência e os metadados da classe interna rotulada como doente; repetir a análise em coortes independentes com processamento homogêneo; incluir controles com doença mamária benigna; separar amostras por indivíduo ou doador; e avaliar experimentalmente um painel pequeno de candidatos. A seleção laboratorial deve priorizar convergência externa, especificidade de braço, plausibilidade bibliográfica e viabilidade técnica, sem reutilizar a GSE73002 para ajustar e validar a mesma versão.

REFERÊNCIAS

ADAM-ARTIGUES, A. *et al.* Identification of a two-microRNA signature in plasma as a novel biomarker for very early diagnosis of breast cancer. **Cancers**, v. 13, n. 11, art. 2848, 2021. DOI: https://doi.org/10.3390/cancers13112848. Disponível em: https://pmc.ncbi.nlm.nih.gov/articles/PMC8201361/. Acesso em: 14 jun. 2026.

ALI, M. *et al.* MicroRNA 21 and microRNA 10b: early diagnostic biomarkers of breast cancer in Egyptian females. **Journal of the Egyptian National Cancer Institute**, v. 34, n. 1, art. 16, 2022. DOI: https://doi.org/10.1186/s43046-022-00115-6. Disponível em: https://link.springer.com/article/10.1186/s43046-022-00115-6. Acesso em: 14 jun. 2026.

ALMOHAYWI, M. *et al.* Deregulated miRNA expression in triple-negative breast cancer of ancestral genomic-characterized Latina patients. **International Journal of Molecular Sciences**, v. 24, n. 17, art. 13046, 2023. DOI: https://doi.org/10.3390/ijms241713046. Disponível em: https://pmc.ncbi.nlm.nih.gov/articles/PMC10487916/. Acesso em: 31 out. 2026.

BEKKER, J.; DAVIS, J. Learning from positive and unlabeled data: a survey. **Machine Learning**, v. 109, n. 4, p. 719-760, 2020. DOI: https://doi.org/10.1007/s10994-020-05877-5. Disponível em: https://doi.org/10.1007/s10994-020-05877-5. Acesso em: 1 nov. 2026.

BENJAMINI, Y.; HOCHBERG, Y. Controlling the false discovery rate: a practical and powerful approach to multiple testing. **Journal of the Royal Statistical Society: Series B (Methodological)**, v. 57, n. 1, p. 289-300, 1995. DOI: https://doi.org/10.1111/j.2517-6161.1995.tb02031.x. Disponível em: https://doi.org/10.1111/j.2517-6161.1995.tb02031.x. Acesso em: 1 nov. 2026.

BRASIL. Conselho Nacional de Saúde. **Resolução nº 510, de 7 de abril de 2016**. Dispõe sobre as normas aplicáveis a pesquisas em Ciências Humanas e Sociais. Diário Oficial da União: seção 1, Brasília, DF, n. 98, p. 44-46, 24 maio 2016. Disponível em: https://www.gov.br/conselho-nacional-de-saude/pt-br/atos-normativos/resolucoes/2016/resolucao-no-510.pdf. Acesso em: 28 out. 2026.

CARDINALI, B. *et al.* Circulating miRNAs in breast cancer diagnosis and prognosis. **Cancers**, v. 14, n. 9, art. 2317, 2022. DOI: https://doi.org/10.3390/cancers14092317. Disponível em: https://www.mdpi.com/2072-6694/14/9/2317. Acesso em: 14 jun. 2026.

CHEN, W. *et al.* The level of circulating miRNA-10b and miRNA-373 in detecting lymph node metastasis of breast cancer: potential biomarkers. **Tumor Biology**, v. 34, p. 455-462, 2013. DOI: https://doi.org/10.1007/s13277-012-0570-5. Disponível em: https://pubmed.ncbi.nlm.nih.gov/23238818/. Acesso em: 14 jun. 2026.

CHEN, X. *et al.* MicroRNAs and complex diseases: from experimental results to computational models. **Briefings in Bioinformatics**, v. 20, n. 2, p. 515-539, 2019. DOI: https://doi.org/10.1093/bib/bbx130. Disponível em: https://doi.org/10.1093/bib/bbx130. Acesso em: 1 nov. 2026.

ELKAN, C.; NOTO, K. Learning classifiers from only positive and unlabeled data. In: ACM SIGKDD INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING, 14., 2008, Las Vegas. **Proceedings** [...]. New York: ACM, 2008. p. 213-220. DOI: https://doi.org/10.1145/1401890.1401920. Disponível em: https://doi.org/10.1145/1401890.1401920. Acesso em: 1 nov. 2026.

GAO, J. *et al.* Clinical significance of serum miR-21 in breast cancer compared with CA153 and CEA. **Chinese Journal of Cancer Research**, v. 25, n. 6, p. 743-748, 2013. DOI: https://doi.org/10.3978/j.issn.1000-9604.2013.12.04. Disponível em: https://pmc.ncbi.nlm.nih.gov/articles/PMC3872537/. Acesso em: 14 jun. 2026.

GARRIDO-PALACIOS, A. *et al.* MicroRNA dysregulation in early breast cancer diagnosis: a systematic review and meta-analysis. **International Journal of Molecular Sciences**, v. 24, n. 9, art. 8270, 2023. DOI: https://doi.org/10.3390/ijms24098270. Disponível em: https://www.mdpi.com/1422-0067/24/9/8270. Acesso em: 14 jun. 2026.

GTEX CONSORTIUM. The GTEx Consortium atlas of genetic regulatory effects across human tissues. **Science**, v. 369, n. 6509, p. 1318-1330, 2020. DOI: https://doi.org/10.1126/science.aaz1776. Disponível em: https://doi.org/10.1126/science.aaz1776. Acesso em: 1 nov. 2026.

GUO, H. *et al.* Plasma miR-1273g-3p acts as a potential biomarker for early breast ductal cancer diagnosis. **Anais da Academia Brasileira de Ciências**, v. 92, n. 1, e20181203, 2020. DOI: https://doi.org/10.1590/0001-3765202020181203. Disponível em: https://www.scielo.br/j/aabc/a/nGpnQS7pCYpkNhrnRvFsqmP/?lang=en. Acesso em: 14 jun. 2026.

HAN, J. G. *et al.* A novel panel of serum miR-21/miR-155/miR-365 as a potential diagnostic biomarker for breast cancer. **Annals of Surgical Treatment and Research**, v. 92, n. 2, p. 55-66, 2017. DOI: https://doi.org/10.4174/astr.2017.92.2.55. Disponível em: https://pmc.ncbi.nlm.nih.gov/articles/PMC5309178/. Acesso em: 14 jun. 2026.

HANLEY, J. A.; MCNEIL, B. J. The meaning and use of the area under a receiver operating characteristic (ROC) curve. **Radiology**, v. 143, n. 1, p. 29-36, 1982. DOI: https://doi.org/10.1148/radiology.143.1.7063747. Disponível em: https://doi.org/10.1148/radiology.143.1.7063747. Acesso em: 1 nov. 2026.

HANNAFON, B. N. *et al.* Plasma exosome microRNAs are indicative of breast cancer. **Breast Cancer Research**, v. 18, n. 1, art. 90, 2016. DOI: https://doi.org/10.1186/s13058-016-0753-x. Disponível em: https://pmc.ncbi.nlm.nih.gov/articles/PMC5016889/. Acesso em: 14 jun. 2026.

HENEGHAN, H. M. *et al.* Systemic miRNA-195 differentiates breast cancer from other malignancies and is a potential biomarker for detecting noninvasive and early stage disease. **The Oncologist**, v. 15, n. 7, p. 673-682, 2010. DOI: https://doi.org/10.1634/theoncologist.2010-0103. Disponível em: https://pubmed.ncbi.nlm.nih.gov/20576643/. Acesso em: 14 jun. 2026.

HUANG, Z. *et al.* HMDD v3.0: a database for experimentally supported human microRNA-disease associations. **Nucleic Acids Research**, v. 47, n. D1, p. D1013-D1017, 2019. DOI: https://doi.org/10.1093/nar/gky1010. Disponível em: https://doi.org/10.1093/nar/gky1010. Acesso em: 1 nov. 2026.

INSTITUTO NACIONAL DE CÂNCER (Brasil). **Controle do câncer de mama no Brasil**: dados e números 2025. Rio de Janeiro: INCA, 2025. Disponível em: https://ninho.inca.gov.br/jspui/handle/123456789/17733. Acesso em: 28 out. 2026.

INSTITUTO NACIONAL DE CÂNCER (Brasil). **Estimativa 2026**: incidência de câncer no Brasil. Rio de Janeiro: INCA, 2026. Disponível em: https://ninho.inca.gov.br/jspui/bitstream/123456789/17914/1/Estima2026_completo%20(1).pdf. Acesso em: 28 out. 2026.

JANG, J. Y. *et al.* Multiple microRNAs as biomarkers for early breast cancer diagnosis. **Molecular and Clinical Oncology**, v. 14, n. 2, art. 31, 2021. DOI: https://doi.org/10.3892/mco.2020.2193. Disponível em: https://pubmed.ncbi.nlm.nih.gov/33414912/. Acesso em: 14 jun. 2026.

KIM, Y. *et al.* Tumor-derived EV miRNA signatures surpass total EV miRNA in supplementing mammography for precision breast cancer diagnosis. **Theranostics**, v. 14, n. 17, p. 6587-6604, 2024. DOI: https://doi.org/10.7150/thno.99245. Disponível em: https://pmc.ncbi.nlm.nih.gov/articles/PMC11519808/. Acesso em: 14 jun. 2026.

KOZOMARA, A.; BIRGAOANU, M.; GRIFFITHS-JONES, S. miRBase: from microRNA sequences to function. **Nucleic Acids Research**, v. 47, n. D1, p. D155-D162, 2019. DOI: https://doi.org/10.1093/nar/gky1141. Disponível em: https://doi.org/10.1093/nar/gky1141. Acesso em: 1 nov. 2026.

LEEK, J. T. *et al.* Tackling the widespread and critical impact of batch effects in high-throughput data. **Nature Reviews Genetics**, v. 11, n. 10, p. 733-739, 2010. DOI: https://doi.org/10.1038/nrg2825. Disponível em: https://doi.org/10.1038/nrg2825. Acesso em: 1 nov. 2026.

LI, M. *et al.* Circulating microRNAs from the miR-106a-363 cluster on chromosome X as novel diagnostic biomarkers for breast cancer. **Breast Cancer Research and Treatment**, v. 170, n. 2, p. 257-270, 2018. DOI: https://doi.org/10.1007/s10549-018-4757-3. Disponível em: https://pubmed.ncbi.nlm.nih.gov/29557526/. Acesso em: 1 nov. 2026.

LIU, Y. *et al.* Serum microRNA-195 as a potential diagnostic biomarker for breast cancer: a systematic review and meta-analysis. **International Journal of Clinical and Experimental Pathology**, v. 12, n. 11, p. 3982-3991, 2019. Disponível em: https://pmc.ncbi.nlm.nih.gov/articles/PMC6949784/. Acesso em: 28 out. 2026.

MAR-AGUILAR, F. *et al.* Serum circulating microRNA profiling for identification of potential breast cancer biomarkers. **Disease Markers**, v. 34, n. 3, p. 163-169, 2013. DOI: https://doi.org/10.3233/DMA-120957. Disponível em: https://pubmed.ncbi.nlm.nih.gov/23334650/. Acesso em: 14 jun. 2026.

MIRANDA, F. S. de *et al.* MicroRNA as a promising molecular biomarker in the diagnosis of breast cancer. **Frontiers in Molecular Biosciences**, v. 11, art. 1337706, 2024. DOI: https://doi.org/10.3389/fmolb.2024.1337706. Disponível em: https://www.frontiersin.org/journals/molecular-biosciences/articles/10.3389/fmolb.2024.1337706/full. Acesso em: 14 jun. 2026.

MITCHELL, P. S. *et al.* Circulating microRNAs as stable blood-based markers for cancer detection. **Proceedings of the National Academy of Sciences of the United States of America**, v. 105, n. 30, p. 10513-10518, 2008. DOI: https://doi.org/10.1073/pnas.0804549105. Disponível em: https://doi.org/10.1073/pnas.0804549105. Acesso em: 1 nov. 2026.

MORDELET, F.; VERT, J.-P. A bagging SVM to learn from positive and unlabeled examples. **Pattern Recognition Letters**, v. 37, p. 201-209, 2014. DOI: https://doi.org/10.1016/j.patrec.2013.06.010. Disponível em: https://doi.org/10.1016/j.patrec.2013.06.010. Acesso em: 1 nov. 2026.

NG, E. K. O. *et al.* Circulating microRNAs as specific biomarkers for breast cancer detection. **PLOS ONE**, v. 8, n. 1, e53141, 2013. DOI: https://doi.org/10.1371/journal.pone.0053141. Disponível em: https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0053141. Acesso em: 14 jun. 2026.

SHEN, J. *et al.* Circulating miR-148b and miR-133a as biomarkers for breast cancer detection. **Oncotarget**, v. 5, n. 14, p. 5284-5294, 2014. DOI: https://doi.org/10.18632/oncotarget.2014. Disponível em: https://www.oncotarget.com/article/2014/text/. Acesso em: 14 jun. 2026.

SHIMOMURA, A. *et al.* Novel combination of serum microRNA for detecting breast cancer in the early stage. **Cancer Science**, v. 107, n. 3, p. 326-334, 2016a. DOI: https://doi.org/10.1111/cas.12880. Disponível em: https://pmc.ncbi.nlm.nih.gov/articles/PMC4814263/. Acesso em: 14 jun. 2026.

SHIMOMURA, A. *et al.* **A novel combination of serum microRNAs for detecting breast cancer in the early stage**. Gene Expression Omnibus (GEO), acesso GSE73002, 2016b. Disponível em: https://www.ncbi.nlm.nih.gov/geo/query/acc.cgi?acc=GSE73002. Acesso em: 11 out. 2026.

SI, H. *et al.* Circulating microRNA-92a and microRNA-21 as novel minimally invasive biomarkers for primary breast cancer. **Journal of Cancer Research and Clinical Oncology**, v. 139, n. 2, p. 223-229, 2013. DOI: https://doi.org/10.1007/s00432-012-1315-y. Disponível em: https://pubmed.ncbi.nlm.nih.gov/23052693/. Acesso em: 14 jun. 2026.

SOCHOR, M. *et al.* Oncogenic microRNAs: miR-155, miR-19a, miR-181b, and miR-24 enable monitoring of early breast cancer in serum. **BMC Cancer**, v. 14, art. 448, 2014. DOI: https://doi.org/10.1186/1471-2407-14-448. Disponível em: https://bmccancer.biomedcentral.com/articles/10.1186/1471-2407-14-448. Acesso em: 28 out. 2026.

SUN, Y. *et al.* Serum microRNA-155 as a potential biomarker to track disease in breast cancer. **PLOS ONE**, v. 7, n. 10, e47003, 2012. DOI: https://doi.org/10.1371/journal.pone.0047003. Disponível em: https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0047003. Acesso em: 14 jun. 2026.

TORAIH, E. A. *et al.* Pilot study of serum microRNA-21 as a diagnostic and prognostic biomarker in Egyptian breast cancer patients. **Molecular Diagnosis & Therapy**, v. 19, n. 3, p. 179-190, 2015. DOI: https://doi.org/10.1007/s40291-015-0143-6. Disponível em: https://pubmed.ncbi.nlm.nih.gov/26063582/. Acesso em: 14 jun. 2026.

TURKOGLU, F.; CALISIR, A.; OZTURK, B. Clinical importance of serum miRNA levels in breast cancer patients. **Discover Oncology**, v. 15, art. 19, 2024. DOI: https://doi.org/10.1007/s12672-024-00871-y. Disponível em: https://pubmed.ncbi.nlm.nih.gov/38280134/. Acesso em: 14 jun. 2026.

VARMA, S.; SIMON, R. Bias in error estimation when using cross-validation for model selection. **BMC Bioinformatics**, v. 7, art. 91, 2006. DOI: https://doi.org/10.1186/1471-2105-7-91. Disponível em: https://doi.org/10.1186/1471-2105-7-91. Acesso em: 1 nov. 2026.

VISHNUBALAJI, R. *et al.* Minimally invasive circulating microRNA signatures for breast cancer detection and neoadjuvant therapy response prediction in a multicenter MENA cohort. **Journal of Translational Medicine**, v. 24, n. 1, art. 1233, 2026. DOI: https://doi.org/10.1186/s12967-026-08452-z. Disponível em: https://pubmed.ncbi.nlm.nih.gov/42415080/. Acesso em: 31 out. 2026.

WANG, F. *et al.* Increased circulating microRNA-155 as a potential biomarker for breast cancer screening: a meta-analysis. **Molecules**, v. 19, n. 5, p. 6282-6293, 2014. DOI: https://doi.org/10.3390/molecules19056282. Disponível em: https://www.mdpi.com/1420-3049/19/5/6282. Acesso em: 14 jun. 2026.

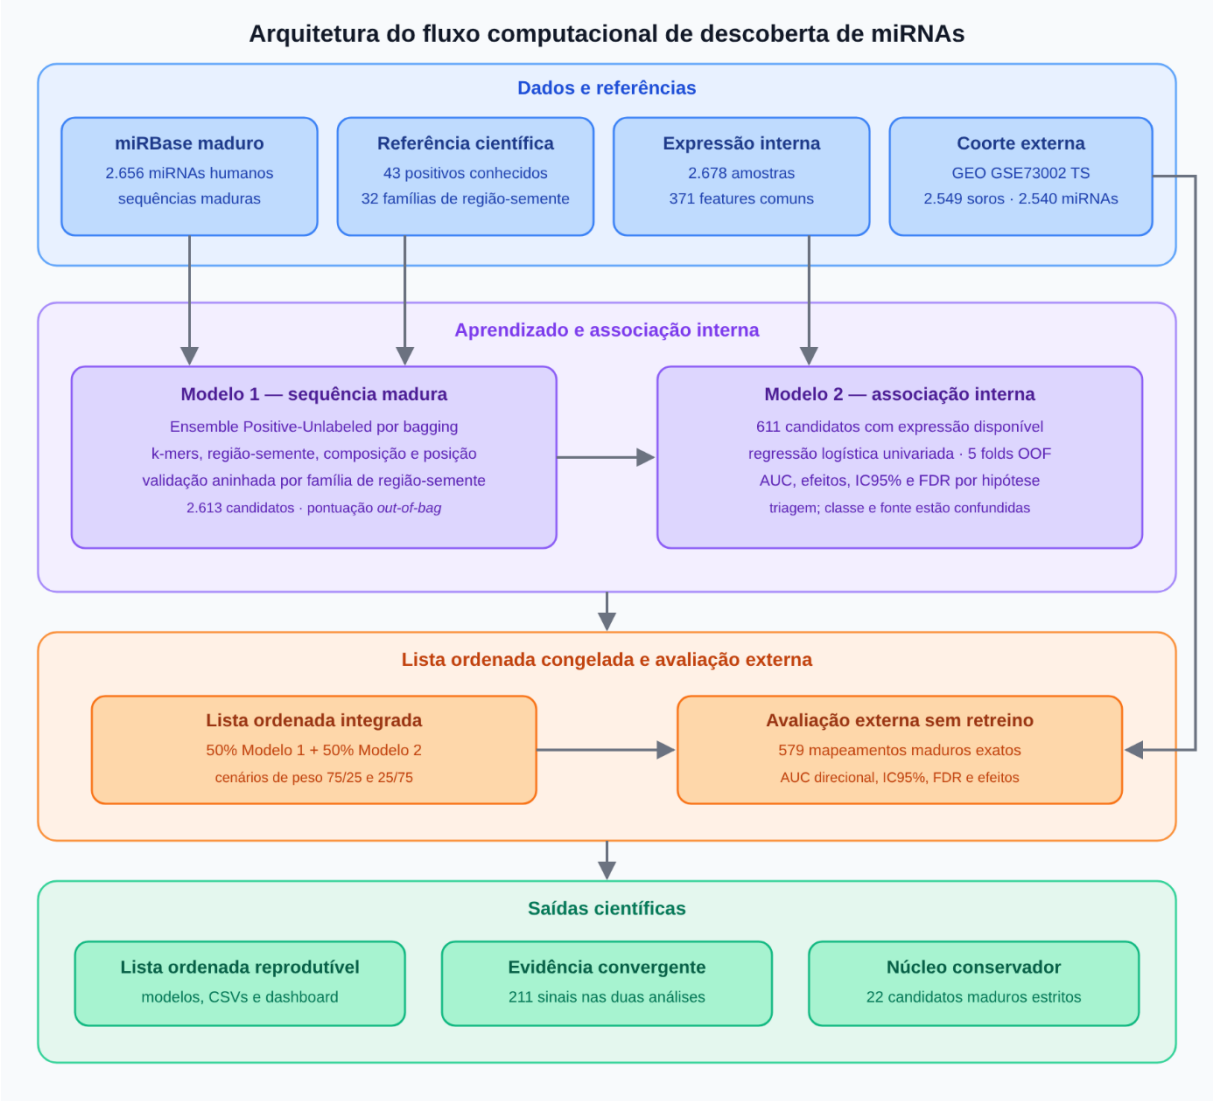
WANG, S. *et al.* Identification of three circulating microRNAs in plasma as clinical biomarkers for breast cancer detection. **Journal of Clinical Medicine**, v. 12, n. 1, art. 322, 2023. DOI: https://doi.org/10.3390/jcm12010322. Disponível em: https://pmc.ncbi.nlm.nih.gov/articles/PMC9821655/. Acesso em: 14 jun. 2026.

ZHU, W. *et al.* Circulating microRNAs in breast cancer and healthy subjects. **BMC Research Notes**, v. 2, art. 89, 2009. DOI: https://doi.org/10.1186/1756-0500-2-89. Disponível em: https://link.springer.com/article/10.1186/1756-0500-2-89. Acesso em: 14 jun. 2026.

APÊNDICE A — ARQUITETURA

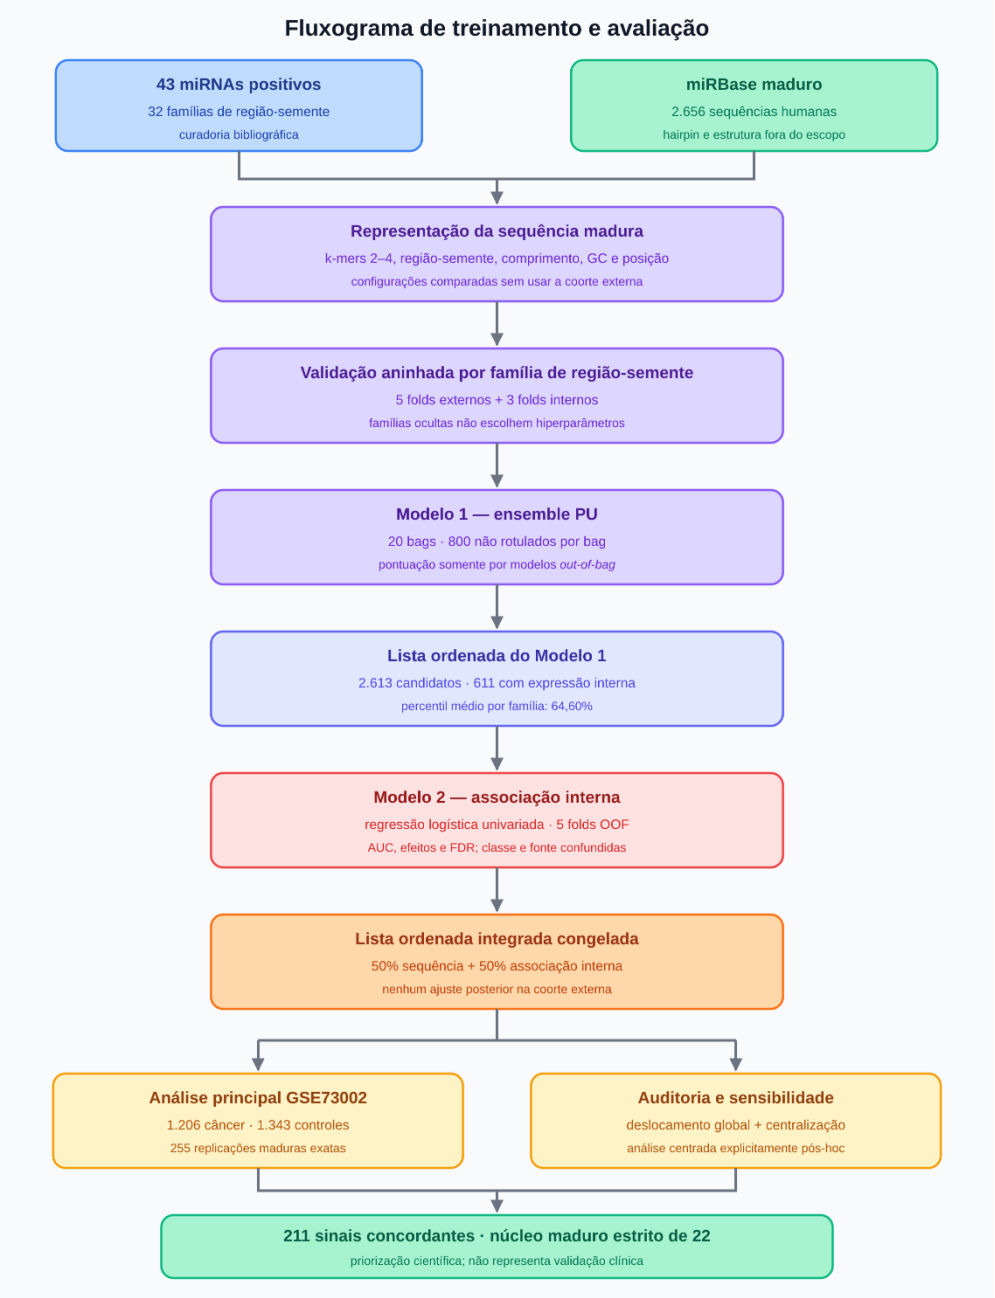
A Figura 1 apresenta a arquitetura geral do fluxo computacional, enquanto a Figura 2 resume o fluxo de treinamento e avaliação.

Figura 1 — Arquitetura do fluxo computacional



Fonte: Os autores (2026).

Figura 2 — Fluxograma de treinamento e avaliação



Fonte: Os autores (2026).